

HR 애널리틱스의 연구동향 및 과제

송기룡* · 김정석**

〈요약〉

HR 애널리틱스는 HRM 분야에 불어온 데이터사이언스의 바람으로 더 객관적으로 효과적인 증거기반의사결정을 위한 노력이자 새로운 방법론이다. 2000년 초반부터 시작된 HR 애널리틱스에 대한 관심은 인공지능과 빅데이터 같은 기술의 발전과 함께 더 부각되어 해외에서는 이미 많은 논의가 진행되고 있다. 이에 반해 국내에는 아직 HR 애널리틱스와 관련된 연구가 충분치 않아 이와 관련된 향후 논의가 요구되는 상황이다. 이에 본 연구는 다음과 같은 세 단계를 통해 HR 애널리틱스의 연구동향 및 시사점을 정리하여 제안하고 향후 연구자들이 기반 삼을 수 있는 HR 애널리틱스의 프레임워크를 제안한다.

먼저, 첫 번째 단계에서는 HR 애널리틱스 연구들을 문헌고찰하고 그 시사점을 도출한다. 연구결과, 세 가지 시사점을 얻을 수 있었는데, 이는 각각 HR 애널리틱스와 관련된 개념적 논의는 충분히 많이 이뤄졌다는 점, 경험적 연구가 부족하다는 점, 그리고, 결국 보다 더 고도화된 방법론이 절실하다는 점이다. 본 단계에서는 시사점과 함께 기존 연구들의 주장을 정리한 개념적 프레임워크 등도 함께 제시한다.

두 번째 단계에서는 문헌고찰 내용을 토대로 HR 애널리틱스의 현재 위치와 앞으로 HR 애널리틱스에 필요한 고도화된 방법론이 무엇인지 알아본다. 연구결과, 비즈니스 애널리틱스 가치모형 상에서 HR 애널리틱스는 기술분석에서 예측분석으로 넘어가는 단계에 머물러 있으며, 앞으로 예측 및 처방분석으로 나아가기 위해서는 머신러닝과 같은 고도화된 방법론이 필요함을 알 수 있다.

마지막으로 앞선 모든 내용들을 바탕으로 향후 연구자들을 위한 하나의 프레임워크를 제안한다. 해당 프레임워크는 본 연구의 최종결과물로서 머신러닝을 이용한 HR 애널리틱스의 프로세스와 각 프로세스마다의 핵심질문 그리고 이에 해당하는 연구이슈들을 포함한다.

키워드: HR 애널리틱스, HR analytics, 인공지능, 머신러닝, HR 예측 및 처방분석

논문접수일 2020년 9월 20일

논문수정일 2020년 11월 9일

게재확정일 2020년 11월 16일

* 경북대학교 경상대학 경영학부 일반대학원 박사수료, giryung.song@gmail.com

** 경북대학교 경상대학 경영학부 교수, kskim@knu.ac.kr

I. 서론

오늘날 관리자들은 최선의 의사결정을 위해 수많은 요소들을 고려해야 한다. 조직성과에 영향을 미치는 무수히 많은 요소들 그리고 그것과 밀접하게 관련된 다양한 이해관계자들은 더 이상 관리자들로 하여금 직관에만 의존하여 결정하도록 내버려두지 않는다. 비록 관리자들의 의사결정이 그들의 경험과 직관에 큰 영향을 받는다고는 하나, 가능한 한 많은 객관적 자료를 함께 고려하여 결정하는 행위, 즉 증거기반 의사결정(evidence-based decision making)은 이제 점점 더 당연한 관행으로 자리잡아가고 있는 것이다(Mclever, Lengnick-Hall & Lengnick-Hall, 2018). 근래 경영학 전반에 걸쳐 불고 있는 데이터 애널리틱스(data analytics)의 바람은 이러한 변화를 단적으로 웅변한다. 비근한 예로서, 데이터 분석기술을 통해 의사결정에 필요한 객관적 자료를 제공하는 작업은 이미 회계, 재무, 생산관리, 마케팅, 기업 간 네트워크 분석 등의 분야에 실제로 도입되어 있으며 동시에 학문적으로도 심층적으로 연구되고 있는 바이며(Jordan & Mitchell, 2015; Earley, 2015; Ward, Marsolo & Froehle, 2014), HRM 분야 역시 이러한 흐름에서 예외는 아니다.

HR 애널리틱스(HR analytics, 이하 HRA)는 더 나은 HRM 의사결정을 위해 종업원과 관련된 다양한 요소들을 데이터화하고 분석하는 과정으로서, HRM 분야에 대한 데이터 애널리틱스의 적용을 의미한다. 이와 유사한 개념은 HRM 연구 초기부터 간간히 연구자들에 의해 언급되어 왔지만 정보량이 크게 증가하고 분석기술이 급속도로 고도화된 최근부터 본격적으로 논의되기 시작했다

(Marler & Boudreau, 2016; King, 2016). 비록 타 분야의 사례들과 비교한다면 논의의 시점이 상대적으로 늦지만, 변화하는 인사관리환경에 발맞출 수 있는 최고의 대안 가운데 하나라는 점에서 이 분야 연구자들 및 실무자들 사이에서 뜨거운 주제로 급부상하고 있다(Tursunbayeva, Lauro & Pagliari, 2018; Minbaeva, 2018; Ransbotham, Kiron & Prentice, 2015). 물론, HRA가 직관보다 더 나은 의사결정 방식인가에 대해서는 여전히 의문이 많지만, 적어도 HRA가 관련 의사결정의 질을 대폭 높여줄 수 있는 또 하나의 획기적인 수단이 되어 줄 수 있다는 점을 의심하는 연구자들은 이제 거의 없다 할 것이다.

이처럼 HRA에 대한 논의가 중대하게 요구되는 시점에서, 본 연구는 현재까지의 HRA 연구가 갖는 시사점을 발견하고 향후 HRA 연구가 가야 할 방향과 과제가 무엇인지 밝히고자 한다. 이러한 시도는 특히 HRA와 관련된 연구가 아직까진 미진한 국내에 HRA를 정리하여 소개한다는 점 그리고 앞으로 많은 연구자들이 HRA와 관련된 연구에 관심을 가지게 할 기반을 제공한다는 점에서 그 의미가 크다 할 것이다. 좀 더 구체적으로는 다음의 단계에 걸쳐 본 연구의 목적을 달성코자 한다.

첫째, 국내 연구가 아직 본격적으로 이뤄지지 않은 상황에서, 현재까지 이뤄진 해외 HRA 연구들을 살펴보고 그 시사점을 도출한다. HRA가 HR 지표(HR metrics)와 관련된 논의들에서 별개로 빠져나와 하나의 연구분야로 본격적으로 다뤄지기 시작한 시점은 2000년 초기부터이다(King, 2016). 따라서 본 연구는 이 시점부터 현재까지의 해외 주요 HRA 연구들의 흐름을 살펴보고자 하는

데, 탄생부터 2016년까지의 흐름은 기존문헌 고찰 연구가 있으므로 이들을 통해 살펴보고, 2016년 이후부터 현재까지의 흐름은 본 연구에서 관련연구들을 직접 문헌고찰하여 그 시사점을 도출하도록 한다.

둘째, 문헌고찰 결과를 바탕으로 HRA가 앞으로 나아가야 할 길을 모색한다. 이를 위해 Lepenioti, Bousdekis, Apostolou & Mentzas (2020)가 제안한 애널리틱스 가치모형을 사용하며, HRA 연구가 어느 단계에 와있는지 그리고 어느 단계로 넘어가야 하는지 파악하도록 한다. 특히 이 과정에서 본 연구는 향후 HRA 연구자들이 집중해야 할 핵심으로서 예측과 처방분석의 중요성을 강조하고 이를 달성하기 위한 대안으로써 AI 기술들 중 하나인 머신러닝을 소개한다.

셋째, 마지막으로, HRA 연구흐름에 머신러닝 기술이 접목될 수 있는 하나의 프레임워크를 제안한다. 이는 HRA 문헌고찰을 통해 얻은 HRA 프로세스와 예측과 처방분석을 위해 살펴본 머신러닝이 결합된 것으로 이를 바탕으로 향후 HRA 연구자들이 보다 더 손쉽게 미래 연구의 방향성을 설정할 수 있을 것으로 기대한다.

II. HR 애널리틱스(HRA) 연구 문헌고찰

리뷰는 2016년을 기점으로 각각 다른 방법으로 진행된다. 2016년 이전 연구흐름의 경우는 기존에 발표된 문헌고찰논문들이 있으므로 이들을 활용하도록 한다. 이 기간에 대한 세부적인 논의는 각 논문들이 잘 설명하기 때문에 본 연구에서는 큰 흐름을 중점적

으로 소개한다. 반면, 2016년 이후부터 현재까지의 HRA연구는 현재의 연구동향과 직접적으로 연관되어 있을 뿐더러 아직 다뤄진 바가 없으므로 본 연구에서 직접 각 문헌들을 검토하고 시사점을 도출한다.

2.1 HR 애널리틱스(HRA)의 탄생과 2016년까지 HRA 연구흐름

HRA이란 “HRM 관련 증거기반의사결정을 위해 내외부의 가능한 모든 HR 변수들을 활용하여 데이터 분석을 수행하고 그 결과를 제시하는 HRM 방법론”이다. 최근 연구로서 많이 다뤄진 예로는 종업원의 이직을 예측하는 사례를 들 수 있는데, 이 연구들은 종업원이 가진 다양한 인구통계변수, 업무수행관련 변수 등을 머신러닝으로 분석하여 해당 종업원이 향후 정해진 기간 안에 이직할 가능성을 예측하는 등의 분석결과를 보여준다(e.g. Khera & Divya, 2019; Valle & Ruz, 2015; Esmaieeli Sikaroudi, Ghousi & Sikaroudi, 2015; Alao & Adeyemo, 2013). 실제 기업의 예로는 IBM과 같은 사례가 있는데, IBM의 경우 그들의 Blue Match 머신러닝 알고리즘을 통해 최대 95퍼센트의 정확도로 종업원의 이직고려 여부를 예측할 수 있다고 발표했다. 또한, 이러한 기술 덕에 HR 인력에 소비되는 비용을 크게 절감한다고 하며 미래에는 더 이상 HR 전문가가 필요 없을 수도 있다고 주장하기도 한다(IBM, 2019). 이 같은 HRA는 과거에도 전통적인 통계 도구들로 특정 HR 지표(HR metrics)들을 계산해내는 방식으로 연구되고 사용되어 왔으나 실제로 그 양과 질에서 부족함이 많았다. 하지만, 근래 들어 급격하게 진행된 데이터 질의 상승과 머신러

닝 또는 딥러닝과 같은 데이터 분석기술 발전은 HRA를 더욱 효과적으로 수행할 수 있는 기반이 되었고, 최근 들어 HRA에 대한 관심의 증가로 이어지게 되었다.

HRA에 대한 언급은 2000년대 초반부터 시작되었으며, 본격적으로 연구가 이뤄지기 시작한 것은 2010년에 들어서면서부터였다 (Marler & Boudreau, 2017). 초창기 HRA와 관련된 연구들은 지엽적인 시각에서 개인을 한 명의 경제활동주체로 보고 그 경제성을 분석해내려 시도했었는데, HRM에 도움이 된다고 여겨지는 몇몇 HR 지표(metrics)들을 꼽고 이들을 계산해내고자 하였다. 이후 점차 HRM 전반과 기업의 전략목표를 함께 고려한 전사적인 관점이 도입되기 시작하였고, 그로 인해 이 개념을 하나의 전략적인 도구로 인식되기 시작하였으며, 인사관리와 관련된 의사결정 전반에 객관성을 담보할 수 있는 핵심으로 여겨지기 시작하였다. 이 시기의 HRA 연구들은 개념적 이슈를 다룬 논문들이 주를 이루었으며, HRA의 정의, 효과성 고찰, 개념적 틀, 절차, 그리고 HRA의 영역에 대해 다양하게 고찰하였다(Ben-Gal, 2019; Rasmussen & Ulrich, 2015).

2016년까지의 연구들은 HRA의 정체성을 잡아가려는 노력들이었다고 보아도 무방하다. 이러한 초창기 연구들은 HRA의 학문적 발전만큼이나 여러 숙제들도 함께 남겨주었다. 우선 개념적 부분에서는 많은 연구자들이 제안했던 논의들을 정리할 수 있는 이론적 틀이 필요하게 되었다. 예컨대, HRA의 정의나 절차 등에 있어 정돈된 하나의 틀이 요구되었으며, 기업의 전략과의 연계되어 HRA가 가져야 할 핵심적인 요소 등에 대한 합의도 요구되었다. 한편, 실질적 부분은 개념적 부

분보다 논의된 바가 적었기 때문에 그 숙제가 명확했다. HRA가 개념적으로는 대단한 가능성을 가지고 있었던 데 반해, 실제로 HR 데이터를 분석하여 현장 관리자들에게 강력한 시사점을 던진 연구는 극히 드물었다. 관념적으로는 수많은 연구들이 이뤄졌지만 정작 경험적으로 그것을 확인한 연구가 적었다. 사실 이 부분이야말로 HRA를 관통하는 가장 핵심적인 숙제라 할 수 있는데, HRA의 본질이 바로 HRM 이론과 현장을 잇는 실용성에 있기 때문이다. 여러 연구자들이 분석기술의 고도화를 강조한 것이 바로 이러한 이유에서였다(Marler & Boudreau, 2017; Angrave, Charlwood, Kirkpatrick, Lawrence & Stuart, 2016; King, 2016).

정리하자면, 2016년 이전의 연구들은 향후 연구들에게 개념적 합의와 경험적 실증이라는 두 가지 화두를 던졌다 할 수 있다. 이를 바탕으로 다음에서는 2016년까지의 연구흐름에 이어 이후 약 5년간의 HRA 연구들을 리뷰해보고 최종적으로 HRA 연구의 현재를 진단하고 그 속에서 얻을 수 있는 시사점들에 대해 논하도록 한다.

2.2 2016년 이후 HRA 연구 문헌고찰

2.2.1 방법론 및 구성

문헌고찰을 위해 다음과 같은 세 가지 단계를 거친다. 첫째, 문헌고찰에 사용될 논문들을 선정한다. 본 연구는 최근 HRA 분야의 주요한 흐름을 파악하기 위해 2016년 이후 현재까지 Clarivate Analytics의 Social science citation index(SSCI)에 등록된 저널의 논문들을 대상으로 지정하였다. 기간을 2016년

이후로 설정한 것은 이 기간 이전의 연구들에 대해서는 문헌고찰이 이뤄져있지만 이후의 연구들에 대해서는 문헌고찰이 이뤄지지 않았기 때문이다.

둘째, 대상 논문들을 범주화하고 개괄적인 내용을 소개한다. 범주화에는 여러 가지 방법이 있을 수 있지만, 시사점을 도출해내기 용이한 방식으로 구분한다. 그리고 각 분야별로의 전반적인 흐름을 소개한다. 추가적으로 그 내용이 특별하여 짚고 넘어가야 할 연구들에 대해서는 구체적인 소개를 담도록 한다.

셋째, 본 장의 핵심으로, HRA 관련 연구들을 살펴본 결과 얻을 수 있는 세 가지 시사점을 제시한다. 이는 2016년 이후 현재까지 HRA 연구흐름을 관통하는 이슈들이며 관련 연구자들이 이전부터 제기해오던 문제점들과 함께 비교되어 제시될 것이다. 더불어 이 시사점들은 다음 파트로 이어져 앞으로 HRA 연구가 극복해야 할 과제들을 도출하는 데 주요한 역할을 할 것이다.

2.2.2 문헌고찰 대상 논문 선정


EBSCO의 ASC(academic search complete)와 BSC(business source complete) 데이터베이스를 이용하였으며, 해당 데이터베이스에서 논문을 검색하기 위해 다음과 같은 검색조건들을 설정하였다. 우선 검색어로는 6가지를 사용하였다. ‘hr analytics’, ‘human resource analytics’, ‘human capital analytics’, ‘people analytics’, ‘talent analytics’, ‘workforce analytics’ 등의 검색어를 입력하였다. 출판연월은 2016년 1월 1일부터 연구수행 당시인 2020년 5월 21일까지로 설정하였고, NAICS 분류를 통해 ‘administration of human resource

programs (except education, public health, and veterans' affairs programs)’로 대상 분야를 한정하였으며, ‘peer reviewed journal’의 논문들만을 대상으로 하였다. 또한, Clarivate Analytics에서 제공하는 Social science citation index (SSCI)에 등록된 저널의 논문들만을 구분해내었다. 검색된 논문들의 주제 및 요약을 확인한 뒤 잘못 검색된 논문, 의학 및 간호 분야와 같이 분야가 다른 논문, 서평이나 편집논평 등은 제외하였다. 최종적으로 리뷰 대상 논문의 편수는 26편이다.

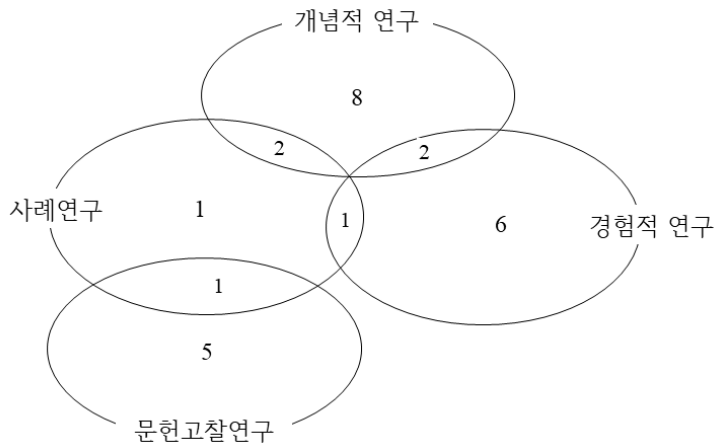
2.2.3 범주화 및 개괄

<그림 1>은 해당 기간 동안 발간된 논문의 편수를 보여준다. 이를 보면 2016년에 비교적 적은 수의 논문이 SSCI급 저널에 발표된 것을 알 수 있다. 2016년에 발표된 논문의 편수가 적은 것이 SSCI급 저널로 그 기준을 한정했기 때문이라 생각할 수 있으나, 실제로 Ben-Gal(2019)에 따르면 그 기준을 peer-reviewed 논문 전체로 넓히더라도 2016년에는 발표 논문의 수가 적은 것을 알 수 있다. 여기에는 여러 가지 이유들이 작용하고 있을 수 있으나, 추론컨대, 2015년까지 1차적으로 증가하던 HRA에 대한 관심이 Rasmussen & Ulrich(2015) 등으로 대표할 수 있는 여러 비판에 의해 잠시 잠잠해 졌던 것이라 판단된다. 이후 2018년까지 논문의 수가 증가하였는데, 다시 2019년에 들어 그 수가 조금 줄어든 것을 알 수 있다. 2020년의 경우 아직 시간이 남았으므로 그 수를 단정하기는 어려워 보인다.

본 연구에서는 연구의 흐름을 손쉽게 파악하기 위하여 먼저 논문의 범주를 개념적 연



<그림 1> 2016년 이후 SSCI급 저널 대상 HRA 논문 편수 추이



<그림 2> 범주별 논문 편수

구(conceptual study), 사례연구(case study), 문헌고찰연구(review study) 그리고 경험적 연구(empirical study)의 네 가지로 구분하였다. <그림 2>는 각 범주에 해당되는 논문의 수이며 범주가 겹치는 경우도 함께 보여주고 있다. 예컨대, 개념적 연구를 수행한 논문의 경우 총 12편이 존재하는데, 이 중에서 사례 연구를 함께 수행한 경우가 2편 그리고 경험적 연구를 함께 수행한 경우가 1편이다. 범주들 중에서 개념 이슈를 다룬 논문이 가장 많다는 것이 큰 특징이라 할 수 있다.

각 범주 별로 조금 더 구체적으로 살펴보면, 먼저 개념연구 논문들은 대부분 HRA의 정의에 대한 논의 보다는 HRA의 개념적 구성이나 프로세스 등을 하나의 프레임워크로 제안하는 것이 거의 대부분이다. 정의의 경우 King(2016), Angrave, Charlwood, Kirkpatrick, Lawrence & Stuart(2016), Marler & Boudreau (2017) 등을 통해 정리가 된 이후에 별다른 논의가 진행되지 않았다. 이외에 HRA를 수행하는 데 필요한 단계들을 프레임워크로 제안한 연구들이 비교적 많았는데, 예컨대, Tambe,

Cappelli & Yakubovich(2019)의 4 steps, McIver, Lengnick-Hall & Lengnick-Hall (2018)의 5 steps, 그리고 Shah, Irani & Sharif (2017)의 SMART 프레임워크 등이 있다. 이들은 조금씩 상이하지만 거의 같은 맥락을 공유하고 있는데 여기에 대해서는 뒤에서 더 구체적으로 논의하도록 한다. 이외에도 Hamilton & Sodeman(2020)은 HRA에 사용될 수 있는 새로운 세 가지 빅데이터 자료 원천을 소개하고 있으며, 또한 빅데이터를 이용한 HRA를 수행함에 있어 발생할 수 있는 법적 그리고 윤리적 문제들을 논의하고 있어 새로운 관점을 제공해준다.

사례연구의 경우 문헌고찰연구 또는 개념연구를 바탕으로 얻어진 프레임워크 등을 사례에 적용하는 방식의 연구가 3편이었으며 경험적 연구와 함께 진행된 경우가 1편 그리고 사례만을 단독으로 분석한 연구가 1편이었다. 다른 범주와 중복되어있는 경우는 대부분 사례연구가 주장하는 바를 뒷받침하기 위한 부가적인 연구로 제시되어 그 비중이 크진 않았다. 다만 다음의 2편의 연구는 눈여겨볼만 하다. Simon & Ferreira(2018)의 경우 자신들이 실제로 ZARA에서 수행했던 HRA 프로젝트 사례를 다루고 있는데, 이들은 ZARA에서 얻어진 다양한 종업원 및 HRM 관련 변수들을 이용하여 군집분석과 비선형 다중회귀분석을 실시하였다. 이를 통해 유의미한 몇 가지 관계들을 밝혀내었는데, 사실 여기서 중요한 것은 그 분석결과보다도 이 프로젝트 과정에서 발생한 학자-실무자 간 차이가 매우 흥미롭게 소개되어 있다는 점이다. 이들이 지적하고 있는 학자-실무자 간 차이의 핵심은 실무자들에게 이론에 기반한 HRA의 적용이 어떠한 의미를 가지고 있는지 이해시키

는 것이었다. 이는 HRA의 현 상황에 대해 중요한 의미를 내포하는데, 그만큼 현재까지의 연구들이 실무자들에게 실용적이지 않은 것으로 여겨진다는 점이다. 이는 곧 뒤에서 논의할 경험적 연구의 부족과도 맞닿아있다.

문헌고찰연구의 경우 총 6편이 존재했으며 그 중 한편은 문헌고찰을 바탕으로 사례연구를 진행한 경우였다. 이들의 경우 시간의 변화에 따라 다소 그 형식의 차이를 보였는데, 최근으로 올수록 관련연구들을 계량적으로 세분화하고 통계화하고자 하는 노력이 더 돋보였다. 예컨대, Tursunbayeva, Lauro & Pagliari (2018)은 People analytics의 키워드를 중심으로 관련 연구들의 트렌드를 다방면에서 통계적으로 기술하였고, Ben-Gal(2019)의 경우 Return of investment(ROI)를 기반으로 하여 기존 연구들을 체계적으로 리뷰하기도 하였다. 또한, Safarishahrbijari(2018) 역시 체계적 리뷰를 통해 기존 연구들을 분야, 연도, 국가, 방법론적 접근법 등에 따른 다양한 정보들을 제공해주고 있다. 다만, 해당 연구들 모두 그 리뷰대상 출간물의 기간이 2016년을 넘지 않는다는 점이 아쉬운 부분이다. 이는 본 연구가 2016년부터 현재까지를 리뷰기간으로 삼은 이유이기도 한데, 가장 최근에 발표된 Ben-Gal(2019)의 리뷰 역시 2016년까지의 연구들을 대상으로 삼고 있어, 그 이후부터 지금까지의 연구에 대해서는 검토된 바가 없다는 것을 알 수 있다.

마지막으로, 경험적 연구가 7편 있었다. 다른 연구 분야들의 흐름을 고려해보았을 때 경험적 연구의 비율이 크게 높지 않다는 것이 일단 가장 큰 특징이라 볼 수 있는데, 이는 다음 파트에서 중점적으로 다루도록 한다. 특징적인 몇 가지 연구들을 짚어보자면, 가장 먼

저 Gelbard, Ramon-Gonen, Carmeli, Bittmann & Talyansky(2018)의 연구를 꼽을 수 있다. 그들은 엔론 기업의 이메일 문치에서 얻어낸 자료들에서 텍스트마이닝 한 뒤 그렇게 얻어진 텍스트들을 대상으로 머신러닝의 한 종류인 나이브베이즈(naive bayes) 분류기를 적용하였다. 이들의 연구는 빅데이터와 관련된 최신의 기술들을 이용하여 작업장에서의 중요한 인적자원요소들의 존재를 입증했다는 점에서 매우 흥미로운 연구라 할 수 있다. 이외에도 Wang & Cotton(2018)의 연구 역시 관심을 끄는데, Major League Baseball(MLB) 선수들의 자료를 이용하여 각 요소들이 최종적으로 승률에 미치는 영향을 분석하고 있다. 비록 기업을 대상으로 한 분석은 아니지만, 스포츠 역시 기업과 마찬가지로 치열한 경쟁 환경과 성과 중심의 문화를 가지고 있음을 고려해본다면 해당 연구의 분석은 충분히 참고할만한 가치가 있는 것이다. <표 1>은 검토된 모든 논문들의 분류 및 핵심 요점들을 정리하고 있다.

2.2.4 HRM 방법론으로서 HRA 연구흐름의 시사점

1) 첫 번째 시사점: 개념적 논의는 충분하다.

HRA 관련 연구들의 문헌고찰을 바탕으로 다음과 같은 시사점들을 논의할 수 있다. 첫째, 개념과 관련된 논의는 충분히 이뤄져왔다는 점이다. 앞선 문헌고찰에서 살펴본 연구들의 범주를 보면 개념적 연구가 가장 많은 수를 차지하고 있음을 알 수 있다. HRA가 하나의 개념으로서 본격적으로 논의되기 시작한 것이 2009년부터라 본다면 이 개념은 이제 10년 남짓 연구되어 온 것이다. 비교적 최신의

개념인 만큼 최근까지도 이와 관련된 논의가 가장 활발하게 이뤄져 오는 것으로 보인다.

개념관련 연구들이 다루는 주제를 구체적으로 들여다보면 크게 개념정의와 프로세스라는 두 가지 부분을 중점적으로 다루고 있음을 알 수 있다. 우선 정의의 경우 King(2016)과 Angrave, Charlwood, Kirkpatrick, Lawrence & Stuart(2016), Marler & Boudreau(2017)의 연구들을 통해 정리된 이후에는 더 이상 관련 논의가 없는 것으로 보아 HRA의 정의에 대해서는 연구자들이 모두 동의하고 있으며 문제 삼을 부분이 없다는 것으로 이해할 수 있다. 실제로도 이후의 연구들을 보면 정의에 대해서는 크게 언급하지 않는 것을 알 수 있다. 이들이 제시하고 있는 정의는 크게 나누어 보았을 때 HRA 대상(What), HRA 방법(How), 그리고 HRA 목적(Why) 등의 요소들로 구분된다. HRA 대상의 경우 비단 HR과 관련된 내부의 요인들에만 국한되지 않으며 관련 있다고 여겨지는 모든 요소들이 그 대상에 포함될 수 있다고 지적한다. HRA 방법의 경우는 고전 통계방법론부터 머신러닝 등의 최신 방법론들을 모두 포함하는 데이터 분석(Data Analytics)이 중심이다. HRA 목적의 경우는 HRM 관련 이슈에 대해 증거기반의사결정(Evidence-based decision-making)을 가능하게 하는 것인데 궁극적으로는 더 객관적이고 합리적인 HR 의사결정을 돕는 것을 목표로 한다. 결론적으로 HRA의 정의를 다시 정리하면 다음과 같다.

HRA란 “HRM 관련 증거기반의사결정을 위해 내외부의 가능한 모든 HR 변수들을 활용하여 데이터 분석을 수행하고 그 결과를 제시하는 HRM 방법론”이다.

<표 1> 문헌고찰 대상 HRA 논문 및 핵심요점

순번	저자	연도	구분	핵심요점
1	Hamilton & Sodeman	2020	개념적 연구	<ul style="list-style-type: none"> - 빅데이터 HRA의 세 가지 과제들: (1) 최상위 의결권자들의 지원 및 HR 전문가들의 지식, (2) 이질적이며 분산되어 있고 전문화되어 있는 데이터들의 분석, (3) 이해관계자들과의 협업 - 세 가지 새로운 데이터 원천: (1) SNS, (2) 비디오 애널리틱스, (3) IoT - 빅데이터 HRA의 윤리적 그리고 법적 고려사항들 - 빅데이터 HRA 의사결정 8 단계
2	Ben-Gal	2019	사례연구	<ul style="list-style-type: none"> - 2000-2016 HRA 논문을 대상으로 한 ROI(return of Investment) 기반 문헌고찰 - 논문 분야 구분: (1) 개념적, (2) 사례기반, (3) 경험적, (4) 기술적 - HRA가 적용될 HR 관련 과업들: 산업분석, 인력 설계, 직무분석, 모집과 선발, 훈련과 개발, 보상, 성과관리, 유지 등 - 실질적 실행 도구들의 구분: (1) 설명 분석도구, (2) 예측 분석도구
3	Tambe, Cappelli & Yakubovich	2019	개념적 연구	<ul style="list-style-type: none"> - HR 생명주기에 따른 예측분석 단계별 과제 제시 - AI 기반 HRM의 네 단계 및 그 과제들: (1) 데이터 생성, (2) 머신러닝, (3) 의사결정, (4) 실행
4	Rebele	2019	개념적 연구	<ul style="list-style-type: none"> - 인적지표를 이용한 개인의 잠재력 검증이 갖는 문제점 제시
5	Claus	2019	개념적 연구	<ul style="list-style-type: none"> - 4차 산업혁명과 인적재능관리(talent management) - 4차 산업혁명 속 인적재능관리의 세 가지 수준별(micro, meso, macro) 해결과제들 - HR 스택 소개: (1) 디자인사고, (2) 애자일 매니지먼트(agile management), (3) 행동경제학, (4) HRA
6	Nankervis, Connell, Cameron, Montague, Prikshat	2019	경험적 연구	<ul style="list-style-type: none"> - HR 실무자들을 대상으로 한 초점그룹 인터뷰 및 설문조사 - 4차 산업혁명과 HRM 변화에 대한 호주기업들의 대처상황 및 현직자들의 의견 정리 및 제시 - HRA 중요성 대두 및 첨단방법론 도입 필요성 지각
7	Laken, Bakk, Giagkoulas, Leeuwen & Bongenaar	2018	개념적 연구	<ul style="list-style-type: none"> - 두 가지 적용 가능한 방법론 제안 - (1) Latent bathtub model, (2) Optimal matching analysis - 각 방법론에 대한 개괄, 장단점, 소프트웨어 등 소개
8	Vargas, Yurova, Ruppel, Tworoger & Greenwood	2018	경험적 연구	<ul style="list-style-type: none"> - 개인의 HRA 수용정도에 영향을 미치는 선행요인 분석 - 계획된 행동이론을 바탕으로 모형수립 - PLS 사용

<표 1> 계속

순번	저자	연도	구분	핵심요점
9	Schiemann, Seibert, Blankenship	2018	사례연구	<ul style="list-style-type: none"> - HR 정보들이 수집되고 저장되고 분석되고 보고되고 있음에도 불구하고 좀 더 유의한 수준으로 올라가지 못하는 원인 탐구 - Jack in the Box 및 기타 사례연구 - 두 가지 프레임워크 기반 (1) Service-profit chain, (2) People equity(ACE profile) - HRA 분석의 가능한 방법들 제안
10	Krscynski, Reeves, Stice-Lusvardi & Ulrich	2018	경험적 연구	<ul style="list-style-type: none"> - HRA 능력이 HR 전문가들의 개인성과에 미치는 영향 분석 - OLS 회귀분석
11	McIver, Lengnick-Hall, Lengnick-Hall	2018	개념+사례 연구	<ul style="list-style-type: none"> - 예자일 HRA(agile workforce analytics) 5 단계 제시 - Foot Locker 사례소개
12	Levenson	2018	개념+사례 연구	<ul style="list-style-type: none"> - HRA 수행의 3 단계: (1) 경쟁우위 분석, (2) 기업 분석, (3) 인적자본 분석 - HRA의 6 가지 핵심영역: (1) 개인역량, (2) 동기 부여, (3) 직무설계, (4) 조직역량, (5) 문화, (6) 조직설계 - HR 효과성 측정의 문제와 대안들 소개 - TD Bank-Canada Trust 합병 사례 소개
13	Simon & Ferreiro	2018	사례+경험적 연구	<ul style="list-style-type: none"> - ZARA 대상으로 수행한 HRA 사례 소개 - 군집분석 + 비선형 다변량회귀분석 - 연구자 실무자 간 차이(gap) 논의
14	Tursunbayeva, Lauro & Pagliari	2018	문헌고찰 연구	<ul style="list-style-type: none"> - People analytics 트렌드 - People analytics 관련 용어사용, 관련 학술연구들, 상업적 People analytics 도구와 서비스들, 온라인 훈련코스 등 소개
15	Minbaeva	2018	개념+경험적 연구	<ul style="list-style-type: none"> - 6 개 기업들과의 HRA 프로젝트 경험, 현장 실무자들 인터뷰, 포커스 그룹 등의 자료 활용 - Human capital analytics의 세 차원: (1) 데이터 질, (2) 분석 역량, (3) 전략적 능력 - Human capital analytics를 위한 조직역량 세 차원: (1) 구성원, (2) 절차, (3) 구조 - 위 차원들에 대한 프레임워크 소개 및 제언
16	Safarishahrbijari	2018	문헌고찰 연구	<ul style="list-style-type: none"> - 2015까지 HRA 연구 문헌고찰 - 분석모형의 세 분류: (1) 필요기반 모형, (2) 요구기반 모형, (3) 공급기반 모형 - 모형의 예들: (1) 질적 모형, (2) 시계열, (3) 최적화, (4) 통계학 및 회귀, (5) 시뮬레이션, (6) 저장 및 유량 분석(analytical stock and flow), (7) 일반 수학적 모형, (8) 신경망, 퍼지분석 등

<표 1> 계속

순번	저자	연도	구분	핵심요점
17	Gelbard, Ramon-Gonen, Carmeli, Bittmann & Talyansky	2018	경험적 연구	<ul style="list-style-type: none"> - 여섯 가지 인적자원 요소 정의: (1) 성과, (2) 몰입, (3) 리더십, (4) 인간관계 역동성, (5) 조직개발에 대한 지원, (6) 학습 및 지식창출 - Enron 사 이메일 말뭉치 분석을 통해 위 여섯 가지 요소들의 잠재적 요인 판별 - 나이브베이즈 분류기를 통한 텍스트마이닝 기법 활용
18	Wang & Cotton	2018	경험적 연구	<ul style="list-style-type: none"> - MLB 데이터 활용 - 선수 개인의 여러 요소들이 팀의 승률에 미치는 영향 연구 - 선형고정효과 모형(linear fixed effect model) 활용
19	Marler & Boudreau	2017	문헌고찰 연구	<ul style="list-style-type: none"> - 2000-2015 HRA 연구들에 대한 증거기반 문헌고찰(evidence-based review) - HRA의 5 가지 주요 이슈: (1) 정의, (2) 프로세스, (3) 이론, (4) 결과물, (5) 조절변수 - LAMP 프레임워크 기반
20	Chamorro-Premuzic, Akhtar, Winsborough, Sherman	2017	개념적 연구	<ul style="list-style-type: none"> - HRA의 세 가지 기술 소개: (1) 디지털 기록을 활용한 머신러닝 분석, (2) 디지털 인터뷰, (3) Gamification (game-based assessment)
21	Lismont, Vanthienen, Baesens, Lemahieu	2017	경험적 연구	<ul style="list-style-type: none"> - 설문자료의 기술적 보고 - 기업의 HRA 성숙도에 대한 설문실시 (cross-sectional worldwide survey) - DELTA 프레임워크 기반: (1) 데이터(data), (2) 기업 또는 조직(enterprise or organization), (3) 리더십(leadership), (4) 목표 또는 기술(target or technology), (5) 분석가(analysts)
22	Baesens, De Winne & Sels	2017	개념적 연구	<ul style="list-style-type: none"> - 전략적 HRM 의사결정에 영향을 주는 성공적 HRA에 대한 네 가지 교훈 소개
23	Shah, Irani, Sharif	2017	개념+경험적 연구	<ul style="list-style-type: none"> - 조직의 변화준비성에 대한 구조방정식 분석 - 일반적인 접근의 문제점 제시 및 빅데이터 분석의 필요성 제기 - 빅데이터의 5 가지 핵심 축 소개(Erevelles, Fukawa & Swayne, 2016; Marr, 2015; McAfee & Brynjolfsson, 2012) - 빅데이터 분석을 위한 5 단계 SMART(Marr, 2015): (1) 전략(strategy), (2) 지표 및 데이터 측정(measuring metrics and data), (3) 분석(analyzing), (4) 결과보고(reporting results), (5) 사업변화(transforming the business) - 빅데이터 리더십의 과제들 소개(McAfee & Brynjolfsson, 2012)

<표 1> 계속

순번	저자	연도	구분	핵심요점
24	Angrave, Charlwood, Kirkpatrick, Lawrence, Stuart	2016	경험적 연구	<ul style="list-style-type: none"> - HRA 정의 - 4 가지 이론화 포인트: (1) HRA 전략 개발, (2) HRA 데이터 및 맥락 이해, (3) 핵심 재능 세분화, (4) 고급분석기술을 통한 데이터기반 의사결정 - HRA 수용의 장애물: (1) HRA의 효용성에 대한 의구심, (2) 소프트웨어 활용 문제 - 향후 과제: (1) 더 나은 기술의 활용, (2) HRA 활용에 대한 설명, (3) 실재론적 그리고 방법론적 접근
25	King	2016	사례+ 문헌고찰 연구	<ul style="list-style-type: none"> - HRA 정의 - HRA 관련 학계의 역할: (1) 분석적 접근에 대한 이해, (2) 머신러닝과 같은 분석도구 활용 - 종업원 이탈율에 대한 R Core Team(2015)의 머신러닝 분석 사례 소개
26	Pape	2016	문헌고찰 연구	<ul style="list-style-type: none"> - 새롭게 접근가능한 빅데이터 아이템의 활용 및 BA(business analytics)의 HR 분야 적용 - HR 프로세스 지도 및 범주화, 가능한 HRA 자료 이슈 및 활용가능한 다양한 지표들 소개

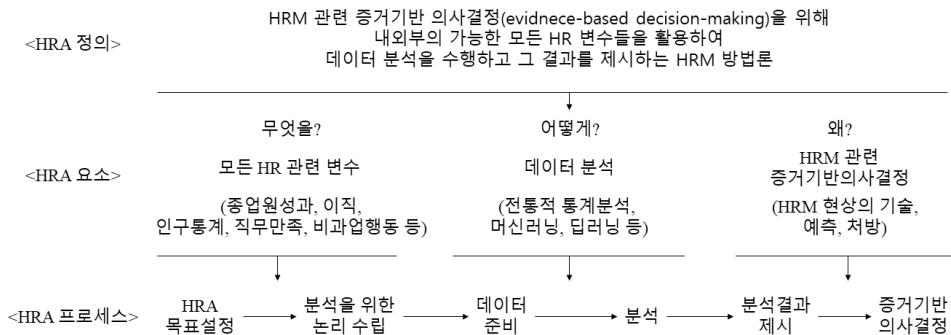
정의 이외에도, 프로세스에 대한 논의 역시 많이 이루어져 왔다. 가장 최근에는 Hamilton & Sodeman(2020)이 실제 의사결정의 관점에서 8단계를 제시한 바 있고, Tambe, Cappelli & Yakubovich(2019)는 머신러닝을 고려한 4단계를 제시하였으며, McIver, Lengnick-Hall & Lengnick-Hall(2018)의 경우는 5 단계, Claus(2019)는 실무적 관점에서의 4 단계, 그리고 Shah, Irani & Sharif(2017)는 SMART라는 프로세스를 제안한 바 있다. 또한, 검토된 논문에서는 구체적으로 나오지 않았지만, 이전부터 언급되었던 LAMP프로세스도 있다(Marler & Boudreau, 2017; Boudreau & Carcio, 2017). <표 2>는 그 구체적 단계들을 정리한 것이다.

제시된 프로세스들을 살펴보면 조금씩 다르긴 하지만, 기본적으로 모두를 관통하는 뿌리가 존재하는 것을 알 수 있는데, 이들을 통

합할 수 있는 HRA의 프로세스를 다시 정리하면 다음과 같은 순서로 정리할 수 있다. (1) HRA 목표설정, (2) 분석을 위한 논리수립, (3) 데이터 준비, (4) 분석, (5) 분석결과 제시, (6) 증거기반 의사결정 이다. 해당 여섯 가지의 단계들 중에서 처음 두 단계를 HRA를 수행해야 할 목적을 찾고 그에 맞는 로직을 세우는 일이다. 이 두 단계 중에서도 특히나 로직을 세우는 부분이 강조되는데, 이는 목적을 제우고 분석의 타당성을 부여 할뿐만 아니라 분석을 통해 얻어진 결과를 설명하는데도 필수적인 과정이라 할 수 있다(Boudreau & Cascio, 2017). 다음의 두 단계는 데이터를 준비하고 분석을 수행하는 단계이며 이는 HRA의 핵심이라 할 수 있다. 해당 부분은 프로세스를 제안한 기존의 연구들 모두 공통적으로 인정하는 부분이라 큰 이견이 없다. 다만 마지막 두 단계의 경우 연구들마다 그 표

<표 2> 기존연구들이 제안한 HRA 프로세스

저자 및 발표년도	제안 프로세스
Hamilton & Sodeman(2020)	기업가치사슬 및 역량 고려 → 주요 문제 설정 → 데이터원천 확인 → 이해관계자들과의 협력 → 데이터분석 → 윤리적 문제 검사 → 분석 결과검토 → 일선관리자의 변화 실행
Tambe, Cappelli & Yakubovich(2019)	데이터생성 → 머신러닝 분석 → 의사결정 → 수행
Mclver, Lengnick-Hall & Lengnick-Hall(2018)	이슈 우선순위 선정 → 영역과 귀납의 통합적 접근 → 데이터준비 → 분석 → 시사점 제공 및 실행
Claus(2019)	프로젝트 파악 → 팀 구성 → 데이터 분석 → 전략실행
Shah, Irani & Sharif(2017)	전략수립 → 데이터 측정 → 분석 → 결과보고 → 실행
Marler & Boudreau, (2017)	로직수립 → 분석수행 → 수치화를 통한 결과제시 → 의사결정 및 실행



<그림 3> 기존연구를 바탕으로 새롭게 정리한 HRA 개념 프레임워크 제안

현이 조금씩 다르다. Tambe, Cappelli & Yakubovich(2019)의 경우는 이를 의사결정(decision making)과 실행(operation)으로, Mclver, Lengnick-Hall & Lengnick-Hall (2018)은 분석결에 대한 이해를 실행으로 옮기는 것(transform insight into action)으로, 그리고 Shah, Irani & Sharif(2017)는 결과보고(reporting results)와 사업변화(transforming the business)로 표현하였다. Claus(2019)는 실무적 관점에서 전략적 행동 선택(take strategic action)이라 하였고, LAMP 프레임워크의 경우는 이 부분을 프로세스라는 명칭으로 포

괄하여 표현하고 있다(Marler & Boudreau, 2017). 비록 이처럼 연구들마다 조금씩의 표현법이 다르긴 하지만, 결국 이들 과정이 담고 있는 것은 HRA를 통해 얻어진 분석을 의사결정권자들에게 제시하고 그 다음의 증거기반 의사결정으로 이어져야 한다는 점은 모든 프로세스들이 공통적으로 포함하고 있다. 따라서 본 연구에서는 마지막 두 단계를 (5) 분석결과 제시, (6) 증거기반 의사결정으로 정하였다. <그림 3>은 이러한 기존연구의 내용을 바탕으로 본 연구가 새롭게 정리한 HRA의 개념 프레임워크이다.

2) 두 번째 시사점: 경험적 연구가 부족하다.

HRA에 관한 연구가 갖는 가장 중요한 시사점은 경험적 연구가 많지 않다는 점이다. 이는 2016년 이전의 연구들에서도 나타났던 동일한 문제점이기도 하다(Ben-gal, 2019). 개념적 연구, 사례연구, 문헌고찰연구 등도 물론 HRA에 대한 이해를 깊이 하는 데 기여하는 것은 맞다. 하지만, 경험적 연구를 통해 야만 보다 더 구체적이고 실질적인 시사점을 얻을 수 있다. HRA는 HRM의 합리적 의사결정을 달성하기 위한 하나의 방법론이기 때문에 실재적인 논의를 통해 이 방법론의 구체안과 그 효과성을 따져보는 것이 핵심이다. 이러한 점은 HRA가 하나의 일시적 유행(fad)으로 그칠 수 있다는 Rasmussen & Ulrich (2015)의 지적과도 맥락을 같이한다. 경험적 증거가 뒷받침되지 않는 개념적 논의는 결국 공허한 외침이 되고 마는 것이다. 문제는 이러한 부족이 현재까지도 해소되지 않고 있다는 점이다.

그 내용을 구체적으로 들여다보면 심각성을 더 자세히 알 수 있다. <표 3>은 2016년 이후 SSCI급 저널에 발표된 HRA 관련 논문들 중 경험적 연구를 수행한 논문들을 보여준다. 해당되는 논문은 총 9편이다. 그런데, 이들 중에서 실제로 HRA라 할 수 있는 분석을 수행한 연구는 Gelbard, Ramon-Gonen, Carmeli, Bittmann & Talyansky(2018)와 Wang & Cotton(2018)의 연구 세 편뿐이다. 이외의 연구들은 HRA를 직접 수행했다기보다는 HRA와 관련된 요소들에 대한 경험적 연구를 수행했다. 예컨대, Nankervis, Connell, Cameron, Montague, Prikshat(2019)의 경우 4차 산업혁명의 변화 속에서 HRA에 대한 HR 실무자들의 생각을 인터뷰 및 설문하였으며, Vargas, Yurova, Ruppel, Tworoger & Greenwood (2018)는 HRA의 수용정도에 영향을 미치는 선행요인을 탐색하였다. Kryscynski, Reeves, Stice-Lusvardi & Ulrich(2018)는 HRA 역량이 HR 전문가의 성과에 어떠한 영향을 미치는

<표 3> 경험적 연구들의 HRA 실제 수행여부

저자 및 발표년도	HRA 실제 수행여부		
	HRA 직접분석 X, HRA 맥락 연구	HRA 분석 직접 수행	머신 러닝 사용
Nankervis, Connell, Cameron, Montague, Prikshat(2019)	○		
Vargas, Yurova, Ruppel, Tworoger & Greenwood(2018)	○		
Kryscynski, Reeves, Stice-Lusvardi & Ulrich(2018)	○		
Minbaeva(2018)	○		
Gelbard, Ramon-Gonen, Carmeli, Bittmann & Talyansky(2018)		○	○
Simon & Ferreiro(2018)		○	
Wang & Cotton(2018)		○	
Lismont, Vanthienen, Baesens, Lemahieu(2017)	○		
Shah, Irani, Sharif(2017)	○		

지 살펴보고, Lismont, Vanthienen, Baesens, Lemahieu(2017) 역시 기업 실무자들을 대상으로 자신들의 기업에 대한 HRA 성숙도를 조사하였다. 이들 연구들은 HRA를 직접 수행한 것이 아닌 HRA의 맥락을 다룬 연구라 할 수 있다.

물론 HRA를 직접 수행하지 않았다고 해서 연구의 가치가 없다는 의미는 절대 아니다. HRA의 맥락을 다룬 모든 연구들 역시 HRA의 중요성, 현장의 HRA 상황 등 나름대로 중요한 시사점을 던져준다. 다만, 본 연구에서 지적하는 것은 HRA의 전체 연구 흐름을 봤을 때 실제로 HRA를 수행하고 이를 보여주는 연구가 턱없이 부족하다는 점이다. 경험적 연구를 수행하고 있는 세 편의 논문과 그 시사점을 살펴보면 다음과 같다. 우선 Gelbard, Ramon-Gonen, Carmeli, Bittmann & Talyansky(2018)의 경우 머신러닝의 한 종류인 나이브베이지 분류기(Naive bayes classifier)를 사용하여 엔론 사의 이메일 말뭉치를 분석하였다. 나이브베이지 분류기는 베이지정리의 조건부 확률을 바탕으로 최종 변수(단어)의 각 분류별 확률을 계산해내는 방법으로 머신러닝 중에서 비교적 간단한 방법에 속한다. 연구자들은 종업원들의 핵심 요소 6 가지를 정의하고 새로운 방법론이 어떻게 잠재적으로 각 요소들을 설명해낼 수 있는지 그 가능성을 보여주었다. 이러한 연구결과는 기존에 사용되어오던 전통적 통계방식에서 벗어나 앞으로 연구자들이 어떤 다양한 방법론과 자료원천을 활용할 수 있는지 중요한 시사점을 제공해주고 있다. 다음으로 Simon & Ferreiro(2018)는 자신들이 실제로 ZARA에 제공한 HRA 사례를 소개하고 있다. 비록 사용된 분석 방법은 다변량회귀분석

으로 기존 연구들이 사용해오던 통계분석방법이지만, 목표 변수 정의, 데이터 특성별 군집분류, 비선형모델을 통한 변곡점 관찰 등 정교한 분석설계를 통해 충분한 결과를 얻어내고 있다. 이에 더하여 해당 HRA 프로젝트 동안 겪은 연구자들과 실무자들 간의 차이를 바탕으로 연구자들이 보완해야 할 사항들을 함께 제시해준다. 마지막으로, Wang & Cotton(2018)은 기업은 아니지만 MLB의 데이터에 선형고정효과모형(Linear fixed effect model)을 적용하여 선수들이 갖는 변수들이 소속팀의 승률에 어떠한 영향을 미치는 지 분석하였다. 스포츠는 기업의 경쟁 못지않게 결과가 중요한 분야이다. Wang & Cotton(2018)은 MLB의 데이터가 다른 어떤 스포츠들보다도 체계화되어 있다는 점에 착안하였고, 선수들 개인의 요소들이 팀의 승률에 어떠한 영향을 미치는지 선형고정효과모형으로 분석을 수행하였다. 비록 기업환경은 아니지만, 해당 연구는 조직의 승패에 영향을 미치는 구성원들의 요소들을 구체적으로 밝혔다라는 점에서 HRA 적용의 가능성을 크게 시사해준다고 볼 수 있다.

살펴보았듯이 HRA의 경험적 연구는 이 분야가 앞으로 나아갈 수 있는 구체적인 길을 제시해줄 수 있다. 따라서 이론적 논의가 충분한 현재 시점에서 HRA에 가장 필요한 것은 구체적인 방법론을 논하고 이를 실제 데이터에 적용해보는 경험적 연구들이라 할 것이다. 다만, 그 구체적 방법론들이 어떤 것이냐에 대해서는 다음에서부터 논하도록 한다.

- 3) 세 번째 시사점: 양질의 시사점을 위한 보다 고도화된 분석방법이 필요하다.

HRA 최근연구들을 통해 알 수 있는 시사

점의 마지막은 고도화된 방법론이 필요하다는 점이다. HR의 수많은 변수들과 조건에 맞게 통합하고 분석하기 위해서는 기존의 전통적 통계방식으로는 한계가 분명하기 때문에 좀 더 고도화된 최신 분석방법이 필요하다. 사실 머신러닝 등으로 대표되는 최신의 분석 방법론들에 대한 요구는 오래전부터 있어왔다. 본 연구에서 검토한 논문들 중에서도 가장 오래된 Angrave, Charlwood, Kirkpatrick, Lawrence, Stuart(2016)이나 King(2016)의 논문들에서도 이미 이러한 고급방법론들에 대한 언급이 있음을 확인할 수 있다. 이러한 언급이 당연한 것이 이미 인사관리가 아닌 경영학의 다른 분야들에는 머신러닝을 포함한 고도화된 방법론들을 이용한 연구가 많이 진행되어 있기 때문이다(Lepeniotti, Boudsdekis, Apostolou & Mentzas, 2020; Lismont *et al.*, 2017; Pape, 2016). 다만, 아쉬운 점은 이러한 방법론들의 필요성에 대한 언급은 있어왔는데 반해 방법론 자체에 대한 구체적인 활용방법 등에 대한 논의가 부족했다는 점이다. 리뷰된 논문들 중에서는 Gelbard *et al.*(2018)이 머신러닝의 한 종류인 나이브베이즈 분류기 사용을 보여준 경우 하나만 있을 뿐이다. 이는 앞서 다룬 시사점인 경험적 연구의 부족과도 맞닿아있다고 볼 수 있다. HRA는 이론의 영역에서 발견되어 온 수많은 요소들을 현실의 시사점으로 변환하는 과정이라 볼 수 있다. 그리고 그 변환의 핵심은 바로 복잡다단한 변수들을 효과적으로 분석할 수 있는 고도화된 분석 방법론이다. 그런데 실제로는 최신의 분석기술들에 대한 논의가 부족하다 보니 의미 있는 시사점을 도출하기 어렵게 되고, 그 결과가 경험적 연구의 부족으로 나타나는 것이라 볼 수 있다.

위에서 살펴본 시사점들을 바탕으로 다음 장에서는 Analytics 가치모형에서 HRA가 갖는 위치 그리고 앞으로 HRA 연구가 나아가야 할 방향 및 과제에 대해서 논하도록 한다. 그 과정에서 문헌고찰을 통해 얻은 시사점인 경험적 연구와 최신 방법론의 요구도 함께 논의된다. 본 장에서는 문제를 지적하는 것에 그치지만 다음 장에서는 보다 더 구체적인 해결방안들이 소개된다.

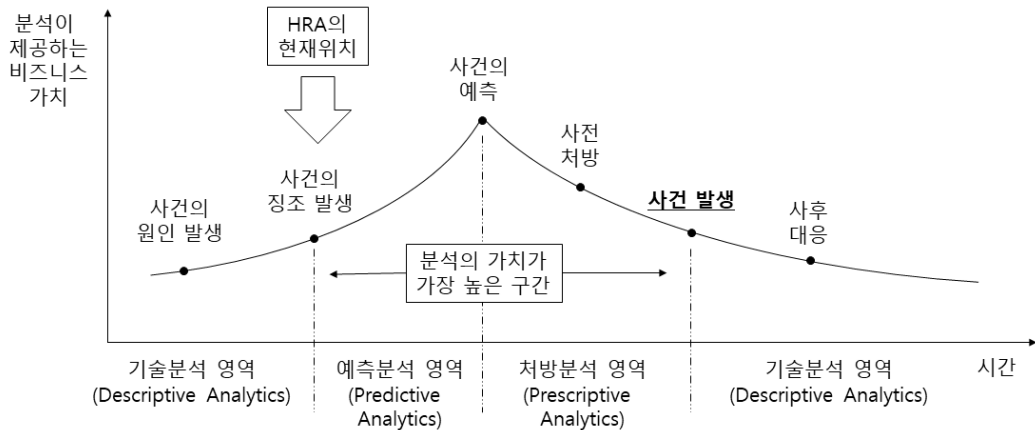
III. HRA와 머신러닝

3.1 애널리틱스 가치모형과 HRA의 현재 위치

앞선 장에서는 HRA의 최신 연구들을 살펴보고 이를 통해 몇 가지 중요한 시사점을 도출하는 과정을 거쳤다. 본 장에서는 애널리틱스가 기업경영에서 갖는 가치에 대해 알아보고 현재 HRA는 어느 단계에 와있는지 그리고 어느 단계로 나아가야 하는지 확인한다. 이후 마지막으로 앞으로 HRA 연구가 해결해야 할 과제 및 그에 대한 구체적인 연구방향들을 제안할 것이다.

최근 Lepeniotti *et al.*(2020)은 경영학 분야 전반에 걸친 애널리틱스의 유행에 대해 그 현황을 파악하고 미래 과제를 진단한 바 있다. 그들은 연구에서 경영관련 사건의 시간흐름 및 애널리틱스 영역에 따라 비즈니스 가치가 어떻게 변하는가를 제시하고 있다. <그림 4>가 바로 그것이다.

해당 모형을 보면 특정 사건이 발생하기 이전부터 시간의 흐름에 따라 애널리틱스의 영역이 함께 변화하는 것을 알 수 있다. 시간



<그림 4> 애널리틱스 가치모형과 HRA의 현재 위치
(Lepenioti *et al.*, 2020의 그림 1을 수정하여 사용)

의 흐름에 따라 순서대로 살펴보면, 가장 먼저 사건의 원인들만 존재하는 상황에서는 기술분석(Descriptive analytics)이 수행된다. 여기서 기술분석이란 이미 발생한 사건들에 대해 그 원인 요소 또는 관련 변수들 간의 인과 관계를 찾아내는 것을 의미하며, 일반적으로 기존의 연구들이 해오던 실증분석들 대부분이 여기에 해당된다. 기술분석의 단계에서는 소수의 변수 간 관계들이 통제조건 하에서 보다 더 엄밀히 분석되며, 개념적 그리고 경험적 타당성을 충분히 갖춘 경우 하나의 이론으로서 받아들여지게 된다. 조직행동분야의 수많은 이론들이 대부분 이 기술분석에 해당된다고 볼 수 있다. 기술분석에서 주로 사용되는 방법론들은 통제된 조건하에서 특정 변수들 간의 관계를 설명하는 데 매우 유용하지만, 반면 통제조건 없이 수많은 변수들의 복잡다단한 조합을 통합하여 계산해야 하는 예측 및 처방의 영역에서는 그 유용성이 떨어진다는 장단점을 갖는다. 다시 말해 기술 통계는 학문의 영역에서 더 유용한 방법론이

라 할 수 있다.

다음으로는 예측분석(predictive analytics)의 영역인데, 이는 사전의 여러 징조들을 통해 향후 일어날 사건의 구체적 사항들을 예측해내는 것을 의미한다. 예측분석은 기존에 기술분석을 통해 설명되어진 다양한 이론들을 특정 방법론들로 통합함으로써 수행될 수 있다. 즉, 예측이 가능하기 위해서는 그 이전에 기술분석을 통해 다양한 변수들 간의 관계가 밝혀져 있어야 한다는 것이다. 예컨대, 종업원의 미래 과업성과를 예측하기 위해서는 그 이전에 종업원의 과업성과에 영향을 미치는 다양한 변수들과의 관계가 이론적으로 충분히 밝혀져 있어야 하는 것이다. 그래야만 과업성과를 예측하는 데 필요한 변수들을 설계하고 관련 데이터를 준비할 수 있기 때문이다.

애널리틱스의 마지막 단계는 처방분석(prescriptive analytics)이다. 처방분석 역시 복잡한 설명변수들을 바탕으로 결과변수의 값을 도출한다는 점은 비슷하지만, 처방분석

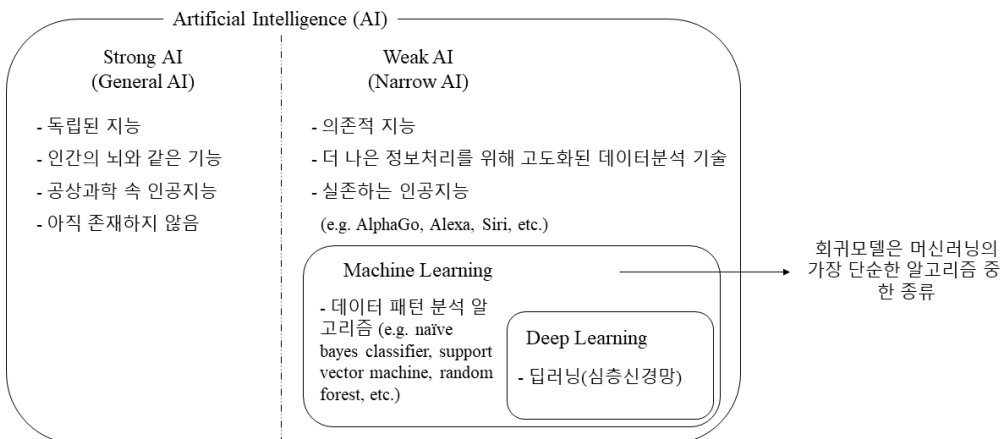
의 차이점은 특정한 처방이 어떠한 결과를 가질지를 확인하기 위한 시뮬레이션이 필요하다는 점이다. 다만, 각 처방에 따른 결과를 예측해야 한다는 점에서 예측분석과 유사한 점이 많으며, 따라서 처방분석에 사용되는 분석방법들은 대부분이 예측분석의 그것들과 겹친다. 현재는 예측분석에 사용되는 여러 방법론들이 처방분석에서 응용되어 연구되고 사용되어 지고 있다(Lepenioti *et al.*, 2020).

한편, 위의 애널리틱스 가치모형을 이용한다면, HRA가 현재 어느 단계에 와있으며 어디로 가야할지에 대해 알 수 있다. 앞선 HRA 리뷰에서 살펴보았듯이 HRA는 아직 개념적 논의가 주를 이루고 있으며, 경험적 연구가 아직 미비한 상황이다. 특히, 머신러닝과 같은 예측과 처방에 특화된 방법론을 다룬 바가 거의 없다. 다만, HRA의 배경이 되는 OB나 HRM과 관련하여서는 수많은 이론들이 밝혀져 있으며, 또한 수많은 실증연구들이 기술분석의 수준에서 이뤄져 있다. 이러한 상황을 미뤄보건대 HRA의 연구는 현재 기술분석 영역과 예측분석 영역의 사이에 위치할

것이라 판단된다. HRA 자체를 수행한 경험적 연구는 많지 않지만, HRA가 기반하고 있는 HRM 및 조직행동분야의 미시적인 현상들에 대해서는 이미 많이 밝혀져 있기 때문이다. 현재 HRA에 필요한 것은 기존에 밝혀져 있는 수많은 이론들, 좀 더 구체적으로는 수많은 독립변수들과 조절 및 매개변수들을 통합하여 실질적인 시사점을 낼 수 있는 분석이 필요한 것이다. 즉, 이제 HRA가 나아가야 할 다음단계는 바로 예측분석의 영역이라 할 수 있다. 애널리틱스 가치모형에 따르면 점차 예측분석 그리고 처방분석의 영역으로 나아가야지만 더 높은 비즈니스 가치를 제공할 수 있기 때문이다.

3.2 예측 및 처방분석을 위한 AI 기술: 머신러닝

앞선 고찰들을 통해 현재까지 데이터분석을 이용한 HRM은 HRA라는 분야를 통해 연구되어 오고 있으며, 그 단계는 기술분석에서 향후 예측분석으로 그리고 궁극적으로는 처



<그림 5> AI의 분류와 머신러닝

방분석으로 넘어가게 될 것임을 알 수 있었다. 이에 본 파트에서는 AI의 기술에 대해서 살펴보고 그 구체적인 기술들 중에서도 어떠한 기술들이 현재 HRA의 부족함을 채워줄 수 있는지 따져보고자 한다.

이를 위해 가장먼저 AI 기술을 개괄적으로 이해할 필요가 있다. 우리는 AI라는 단어에 매우 친숙하지만 사실 그 구체적인 내용에 대해서는 무지하거나 혹은 오해하고 있는 경우가 많기 때문이다. 연구자들마다 조금씩 상이하지만, AI는 크게 두 가지 영역으로 구분된다. <그림 5>는 AI의 구분을 도식화한 것이다. 한 가지는 Strong AI(혹은 General AI)라고 불리고 다른 하나는 Weak AI(또는 Narrow AI)라 불린다(Pennachin & Goertzel, 2007; Searle 1980). 사람들은 보통 AI를 떠올릴 때 영화 속에 나오는 AI들을 그린다. 터미네이터의 Skynet이나 아이언맨의 Jarvis와 같이 스스로 질문을 던지고 스스로 판단할 줄 아는 독립적인 지성체가 AI라고 생각한다. 하지만, 여기서 큰 오해가 발생한다. 앞서 말한 독립적인 지성체로서 AI는 Strong AI에 해당하는데, 안타깝게도 아직 인류는 Strong AI를 현실에서 가져본 적이 없다. 우리가 일상에서 접하는 모든 AI는 Weak AI에 속하며 이들은 사실 하나의 독립적인 지성체기 보다는 정보처리를 돕는 알고리즘 복합체에 더 가깝다. 그렇게 본다면 사실 현재 우리가 사용하는 AI는 우리가 상상 속에 그리는 그 AI가 아닌 것이다. 이는 굉장히 중요한 포인트이다. AI 기술을 활용하기 위해서는 그것에 대해 명확히 인지해야 하고, 우리가 AI에 대해 가지고 있는 막연한 기대를 없애야하기 때문이다.

한편, 현재까지 개발되어 사용되고 있는

Weak AI의 기술들 중에서 HRA에 필요한 예측분석과 관련되어 최근 가장 각광받는 것이 바로 머신러닝이다. 머신러닝이란 애초에 인간의 연산능력으로는 발견할 수 없는 복잡한 수학적 해를 컴퓨터의 반복 연산을 통해 발견하는 것을 의미한다. 그렇기 때문에 넓은 의미에서의 머신러닝에는 연구자들이 보편적으로 사용하는 선형회귀분석 역시 포함된다. 데이터의 분포 속에서 최적의 회귀선을 찾아내는 것 역시 컴퓨터의 반복연산을 통해 이뤄지기 때문이다. 다만, 실제로는 복수의 단계로 이루어진 연산 알고리즘들만을 머신러닝으로 칭하여 사용하는 것이 일반적이다. 여기에 해당하는 알고리즘들로는 나이브베이지, 의사결정나무 또는 랜덤포레스트, 서포트벡터머신, K-근접이웃분석, 심층신경망(딥러닝) 등이 있다. 이러한 머신러닝은 충분한 학습용 데이터(training data)가 존재할 경우 각 알고리즘에 맞는 최적의 해를 찾아낼 수 있고 이를 바탕으로 새롭게 주어지는 데이터의 값을 높은 확률로 예측할 수 있다는 강령함을 갖는다. 이것이 기술의 발전과 함께 머신러닝이 주목받는 가장 큰 이유이다. 특히, 머신러닝 기술들 중에서도 최근 각광받고 있는 기술이 있는데 이것이 바로 심층신경망이다. 이는 머신러닝의 한 종류인 인공신경망이 더 많은 다층의 구조로 이루어진 것 모형을 말한다. 이 심층신경망은 개별 연산 알고리즘인 퍼셉트론을 어떻게 변경하고 배치하느냐에 따라 엄청나게 많은 방식으로 응용이 가능하여 최근까지 점점 더 많은 연구자들과 실무자들의 관심을 받고 있으며, 다층신경망 알고리즘은 이미 비즈니스 분야에서도 HR 분야를 제외하고는 수많은 분야들에서 연구 및 사용되어오고 있다(Tkáč & Verner, 2016).

<표 4> 예측 및 처방분석을 위한 머신러닝의 대표적 알고리즘들

알고리즘	설명
나이트베이즈	<ul style="list-style-type: none"> - 베이스 정리의 조건부확률을 기반으로 결과변수가 특정 범주에 속할 확률을 계산 - 복수의 연산으로 이뤄져있지는 않으나 연산 자체가 복잡하여 머신러닝의 알고리즘으로 여겨짐
의사결정나무 & 랜덤포레스트	<ul style="list-style-type: none"> - 의사결정나무: 특정 조건 하에서 네 또는 아니오로 분류되는 의사결정 단계가 복합된 알고리즘 - 랜덤포레스트: 복수의 의사결정나무들로 이뤄진 알고리즘이며 배깅이나 랜덤스페이스 등의 작업을 통해 예측의 성능을 높인 알고리즘 - 랜덤포레스트의 일종인 XGBoost는 가장 뛰어난 예측성능을 보이는 알고리즘 중 하나로 알려져 있음
서포트벡터머신	<ul style="list-style-type: none"> - 데이터 분포 속에서 각 범주의 경계 부근에 있는 서포트벡터들을 이용해 최적의 구분선을 찾는 알고리즘
K-근접이웃분석	<ul style="list-style-type: none"> - 특정한 데이터에 대해 K개의 근접한 이웃 데이터의 분류 또는 수치를 바탕으로 해당 데이터의 분류 또는 수치를 예측하는 알고리즘
심층신경망 (딥러닝)	<ul style="list-style-type: none"> - 입력된 값을 특정 함수로 계산하여 출력하는 단일 퍼셉트론이 다수 및 다층으로 연결된 인공신경망 - 입력층과 출력층 사이에 다수의 은닉층을 가져 복잡한 정보를 동시에 처리하거나 데이터에 속에 숨겨진 특징들을 잡아낼 수 있다는 장점을 지님 - 신경망의 종류가 다양하고 응용가능성과 잠재력이 매우 높아 최근 가장 주목받는 알고리즘

<표 4>는 머신러닝의 대표적 알고리즘들을 정리한 것이다.

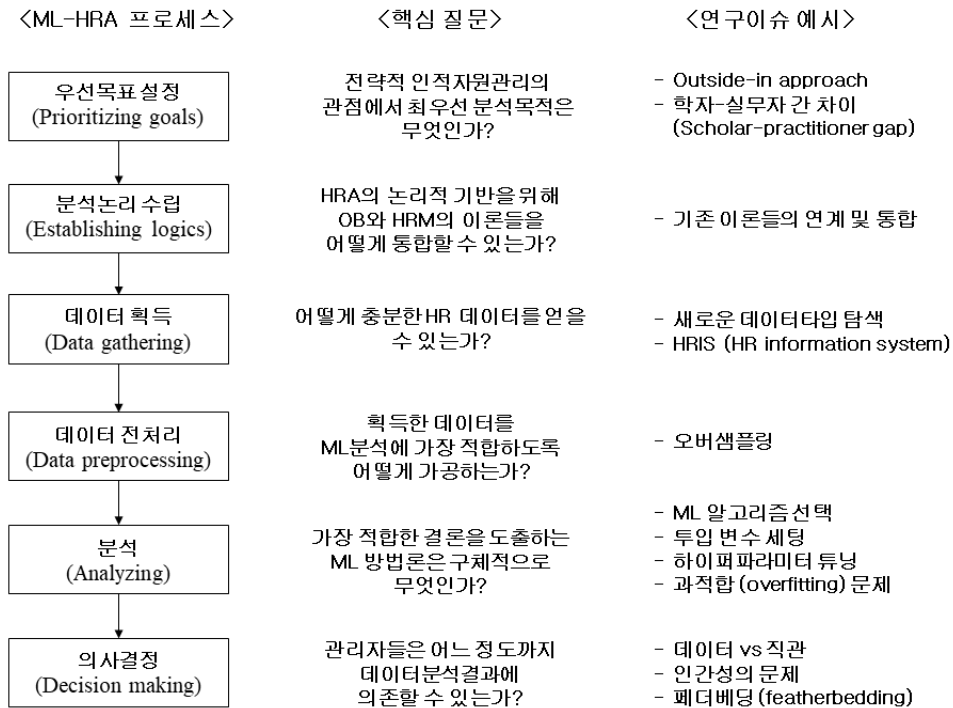
IV. 머신러닝을 이용한 HRA(ML-HRA)의 프레임워크 및 핵심이슈

HRA의 문헌고찰을 통해 새로운 방법론을 활용한 경험적 연구의 필요성을 확인하였고 애널리틱스 가치모형을 바탕으로는 HRA가 현재 기술분석의 단계에 있으며 이제 예측분석의 단계로 나아가야함을 알 수 있었다. 그리고 AI 기술들 중에서 머신러닝 기술을 활용하면 HRA에 필요한 예측 및 처방분석이 가능하다는 것을 알았다. 이에 본 연구는 마

지막으로, 현존하는 분석도구들 중에서 머신러닝을 활용한 HRA의 프레임워크를 제안하고 각 단계에 따른 핵심질문들과 고민해볼 만한 연구이슈들을 논하고자 한다. 이 프레임워크는 앞선 HRA리뷰들에서 얻은 통합된 HRA 프레임워크를 기반하고 있다. 다만, Data preparation이 Data collection과 Data preprocessing으로 나뉘어졌으며 Result presenting이 사라졌는데, 이는 머신러닝이 갖는 특성을 반영하여 연구자가 수정한 것이다. <그림 6>은 이를 정리한 것이다.

4.1 우선목표 설정(Prioritizing goals)

ML을 활용한 HRA의 프레임워크에서 첫 번째 단계는 HRA 활동을 위한 목표를 세우



<그림 6> 머신러닝을 통한 HRA(ML-HRA) 프레임워크

는 일이다. 이 단계에서 세워진 목표는 이후 HRA의 모든 과정들이 따라야 할 최우선 가치가 된다. 따라서 올바른 목표를 세우는 것이 중요한데, 이를 위해 연구자들이 던져야 할 질문은 ‘어떠한 목표가 기업의 전략적 관점에서 가장 우선시 되는가?’이다. Rasmussen & Ulrich(2015)는 일찍이 이러한 부분을 지적한 바 있는데, HRA가 그 배경이론 및 분석 기법 등에만 매몰될 경우 정작 가장 중요한 비즈니스 가치를 잃어버릴 수 있다고 주장하였다. 아무리 논리적이고 정교한 분석이 이루어졌다 한들 그것이 해당 기업의 전략방향과 무관하다면 이는 에너지 낭비일 뿐이기 때문이다. 이러한 문제를 해결하기 위해 그들은 Outside-in approach를 강조하였는데, 이는 HRA의 수행동기가 직접적으로는 기업의 전

략, 간접적으로는 기업의 환경 및 이해관계자들을 모두 고려하여 발생해야 된다는 점을 강조한다.

이에 더하여 HRA의 목표를 설정하는 과정은 HRA를 수행해야 할 타당성을 부여하는 과정이기도 하다. 기업의 맥락을 따르는 HRA 목표를 설정해야지만 실무자들로 하여금 HRA를 수행할 동기를 갖게 만들 수 있다. 만약 이러한 타당성부여가 충분하지 않다면, 분석을 수행하는 쪽과 받아들이는 쪽 간에 심각한 Gap이 발생할 수도 있다(Simón & Ferreira, 2018).

4.2 분석논리 수립(Establishing logics)

이 프로세스의 두 번째 단계는 목표를 분

석해내기 위해 필요한 이론적 토대를 만드는 일이다. 앞서 살펴보았듯이 HRA가 현재 지향해야 할 분석단계는 바로 예측분석이다. 이 예측분석은 기존에 존재하던 수많은 이론들을 통합함으로써 달성할 수 있다. 예를 들면, 조직시민행동과 같은 변수를 머신러닝을 통해 예측한다고 할 때, 기존 연구들이 이미 밝혀놓은 조직시민행동의 동기인 사회교환동기, 기질특성, 인상관리동기 등(Organ, Podsakoff & MacKenzie, 2006; Bolino, 1999)을 바탕으로 그와 관련된 직무만족, 성격변수, 인상관리욕구와 같은 설명변수들을 선정할 수 있는 것이다. 잘 알다시피 HRM, 종업원심리 및 행동과 관련하여 기존에 이미 수많은 변수들 간의 관계가 밝혀져 있고 이러한 이론적 기반은 목표로 하는 변수를 예측하기 위한 설명변수 조합을 선정하는 데 가장 중요한 단서가 된다. 한편, 만약 설명하고자 하는 대상 변수에 대해 다양한 이론들이 존재하고 심지어 상충되는 이론들이 존재하는 경우는 이들을 통합할 수 있는 방법에 대해 깊게 고심해볼 필요도 있을 것이다.

4.3 데이터 획득(Data gathering)

머신러닝을 이용한 HRA를 위해 다뤄야 할 세 번째 단계는 바로 데이터 획득이다. 머신러닝은 기본적으로 다수의 변수들을 바탕으로 복잡한 연산과정을 거친다. 따라서 이들이 예측을 위한 최적의 모형 및 파라미터를 찾아내기 위해서는 학습을 완료 할 수 있는 충분한 양의 데이터가 필요하다. 머신러닝이 빅데이터와 주로 함께 다뤄지는 이유가 바로 여기에 있다. 또한, 모든 데이터사이언스에 적용되듯이 양 뿐만 아니라 결과를 도출하기

위한 양질의 정보가 담긴 데이터를 준비할 필요가 있다. 이를 위해 실제로 몇몇 기존 연구들은 새로운 데이터 원천을 찾기 위한 다양한 노력을 시도 중이다. Hamilton & Sodeman (2020)의 경우 새로운 데이터 원천으로서 SNS 속 종업원들의 활동, 영상 속에 나타나는 행동패턴, 사물인터넷(IoT)을 이용한 자료 등을 제안하였으며, Gelbard *et al.*(2018)은 이메일 속에서 텍스트마이닝을 통해 얻은 말뭉치 등이 HRA의 데이터가 될 수 있음을 보였다.

한편, 다양한 HR 데이터 원천을 찾는다는 구체적인 이슈 외에도 이보다 더 거시적인 의미에서 HR 데이터를 획득 및 관리하기 위한 개념이 존재하는데, 이것이 바로 HRIS(human resource information system)이다. 이 개념은 HR과 관련된 데이터들을 획득하고, 저장하고, 수정 및 분석하고, 분배 및 회수하는 모든 과정을 담는 시스템을 의미한다(Tannenbaum, 1990). HRA 역시 분석의 위한 설계부터 데이터 수집 그리고 분석 및 제안까지를 포함하는 개념임을 생각해본다면 HRIS와 HRA는 서로 겹치는 부분이 많으며 서로 상호보완적 관계를 갖는다 할 수 있다(Ngai & Wat, 2004). 다만, HRIS는 HR과 관련된 정보의 흐름에 초점을 둔 반면, HRA는 데이터를 활용한 분석 자체에 초점을 두고 있다. 본 연구에서 HRIS를 소개하는 것은 이것이 HRA를 위한 데이터들을 더 효과적으로 획득하고 관리할 수 있는 기틀이 될 수 있을 것이라 믿기 때문이다. 실제로 여러 연구자들이 올바른 HRIS를 설계하기 위해서는 조직이 가진 전략적 분석목표와의 연계가 중요함을 지적하고 있는데(Mayfield, Mayfield & Lunce, 2003), 이 전략적 분석목표라는 것이 결국은 HRA를 어떻게 수행하고 그 결과를 어떻게

제시하는가를 의미한다고 볼 수 있다. 예컨대, 특정기업이 종업원들의 정서적 안정감을 분석하고 이를 능동적으로 관리하고 싶어 한다고 하자. 그렇다면, 이 기업의 HR팀은 종업원의 정서적 안정감을 효과적으로 분석할 수 있는 분석 알고리즘을 찾아냄과 동시에 그 알고리즘이 요구하는 데이터를 질적 그리고 양적으로 충분하게 준비해야 할 것이다. 그리고 HRIS는 그러한 전략적 목표에 맞게 가장 효과적이고 효율적으로 적절한 데이터를 발견하고 수집하고 저장할 수 있도록 설계되어야 하는 것이다. 그렇게 본다면, 앞으로는 각 HRA와 연계된 최적의 HRIS를 고안하고 이를 경험적으로 증명하는 연구가 많이 이뤄져야 할 것이라 판단된다.

4.4 데이터 전처리(Data preprocessing)

데이터를 수집한 뒤에는 본격적인 분석을 위해 데이터의 전처리 과정을 거쳐야 한다. 물론 이것이 비단 HR분야에만 적용되는 문제는 아니겠지만, HR분야의 데이터들은 그 특성상 데이터의 축적이 용이하지 않은 경우가 많고 특히 설문으로 데이터를 수집하는 경우는 그 양이 머신러닝 등과 같은 복잡한 연산 알고리즘을 통과하기에는 충분하지 않은 경우가 대부분이다. 또한, HRIS가 제대로 구축되지 않은 시점에서는 필요한 데이터와 그렇지 않은 데이터가 하나에 혼재되어 있거나 데이터의 구성이 불균형(imbalanced)하게 형성되어 있는 경우도 많다. 앞서 언급했듯이 이러한 문제를 해결할 수 있는 가장 좋은 방법은 애초에 필요한 HR 데이터들을 효과적으로 획득할 수 있는 최적의 시스템을 개발하는 것이지만, 그렇지 못했을 경우에 대비한

다양한 데이터 처리방법 역시 고안되어야 할 것이다. 다행히도 데이터사이언스 분야는 주어진 데이터가 가진 부족이나 불균형 등의 문제를 해결할 수 있는 다양한 데이터 전처리 방법들을 발견하기 위해 노력하고 있으며, HRA 연구자들은 그들 중에서 가장 우리 분야에 적용할 수 있는 적절한 방법론들을 찾고 이를 경험적으로 확인해야 할 것이다. 여기에 대해 조금 더 구체적으로 설명하면 다음과 같다. 일반적으로 데이터의 부족한 수와 불균형 문제를 해결하기 위해 가장 많이 알려진 전처리 방법은 오버샘플링(over-sampling)이다. 이는 주어진 데이터를 바탕으로 새로운 데이터를 생성하여 기존 데이터가 가진 불균형을 해소하는 방법으로, 동시에 머신러닝을 위한 충분한 데이터를 확보할 수 있는 등의 장점을 갖는다. 연구자들에게 가장 친숙한 오버샘플링 기법은 아마도 부트스트래핑일 것이다. 다만, 부트스트래핑의 경우 주어진 데이터 중에서 무작위로 새로운 데이터를 복제해내기 때문에 데이터의 불균형을 해소하는 데는 크게 효과적이지 않은 것으로 알려져 있다. 그 대신 머신러닝의 다양한 알고리즘들 활용하여 더 효과적인 오버샘플링 기법들이 발견되고 있다. 예컨대, K-근접이웃, 서포트벡터머신, 나이브베이즈 분류기 등을 활용한 SMOTE(synthetic minority over-sampling technique, Wang, Chao & Cao, 2012; Tang, Zhang, Chawla & Krasser, 2008; Han, Wang & Mao, 2005; Chawla, Bowyer, Hall & Kegelmeyer, 2002), 의사결정나무의 일종인 CART(classification and regression tree)를 활용한 기법(Reiter, 2005) 등 다양하다. 거기다 최근에는 심층신경망의 변증적 양상 불 알고리즘인 GAN(generative adversarial

networks)을 통한 오버샘플링 기법까지 연구되고 있다(Xu, 2020).

4.5 분석(Analyzing)

다섯 번째 단계로 가장 중요한 데이터 분석이 이뤄지게 된다. 머신러닝의 다양한 알고리즘들을 HR 데이터에 적용하여 특정 값들을 예측해내는 경험적 연구가 수행되는 것이다. 이를 위해서는 다음과 같은 세 가지 핵심 내용들에 대해 앞으로 논의되어야 하는데, 이는 각각 알고리즘 선택, 변수(머신러닝에서는 ‘Feature’라는 단어를 사용하나 본 연구에서는 이해를 돕기 위해 ‘변수’를 사용) 엔지니어링, 그리고 하이퍼파라미터(hyperparameter) 튜닝이다. 이들 모두 머신러닝을 수행할 때 고려해야 하는 필요 사항들과 같다. 가장 먼저, 주어진 HR 데이터에서 목표로하는 값을 예측하기 위해 어떠한 머신러닝 알고리즘을 사용할지 선택하는 것이 중요하다. 이와 관련하여서는 이미 기존에 컴퓨터 사이언스 분야의 연구들을 참고하는 것이 좋다. 이 분야의 연구자들은 오래전부터 종업원의 이직을 예측하기 위해 다양한 머신러닝 알고리즘들을

적용하고 이들의 성능을 비교분석 한 바 있다. <표 5>는 이에 해당하는 연구들 중 일부를 간략하게 소개한 것이다.

위 연구들의 분석결과를 살펴보면, 각 알고리즘들마다 주어진 조건하에서 서로 다른 예측성능을 보인다는 것을 알 수 있다. 물론 충분한 데이터가 뒷받침되는 경우 알고리즘들이 보여주는 성능은 비슷하지만, 데이터 조건이 충분하지 않은 경우가 많다는 점을 고려하면 알고리즘의 선택은 매우 중요하다. 향후 다양한 HR 데이터 및 분석목적에 따라 어떠한 알고리즘이 가장 적합한 지 찾아내는 연구가 요구되는 이유이다.

알고리즘 선택 다음으로는 변수 엔지니어링이 중요하다. 이는 머신러닝의 학습을 위해 제공하는 변수의 조합을 특정 하는 과정을 의미하는데, 여기서 굳이 엔지니어링이라는 표현을 쓰는 이유는 이것이 데이터 수집 사전의 변수선택도 포함하지만 동시에 사후 변수 정규화(regularization)와 같은 기술적 처리도 포함하기 때문이다. 머신러닝을 수행하기 위해서는 학습을 위해 특정한 변수들과 그 값들을 제공해주어야 한다. 여기서 중요한 점은 순도가 높은 변수 조합을 제공할수

<표 5> 다양한 머신러닝 알고리즘을 활용한 종업원 이직 예측 연구들

연구	사용된 머신러닝 알고리즘
Khera & Divya(2019)	서포트벡터머신
Valle & Ruz(2015)	랜덤포레스트, 나이브베이즈
Easmaeeli Sikaroudi, Ghousi & Sikaroudi(2015)	다층퍼셉트론, 확률신경망, 서포트벡터머신, CART, K-최근접이웃, 나이브베이즈, 랜덤포레스트
Alao & Adeyemo(2013)	의사결정나무의 다양한 종류들(C4.5, CART, SeeTree 등)
Saradhi & Palshikar(2011)	서포트벡터머신, 랜덤포레스트, 나이브베이즈
Jantan, Hamdan & Othman(2010)	의사결정나무(C4.5)
Sexton, McMurtry, Michalopoulos & Smith(2005)	신경망

록 최종 분석의 예측도가 높아질 수 있다는 것이다(Blum & Langley, 1997). 너무 적은 정보를 제공하면 분석의 정확도가 떨어질 것이고 너무 많은 정보를 제공하면 과적합(over-fitting) 등의 문제로 일반화가 어려워질 수 있다(Yarkoni & Westfall, 2017). 머신러닝이 아무리 최선의 방법론이라 하더라도 기본적으로 이 방법 역시 주어진 데이터가 가진 정보를 이용하는 것이다. 따라서 올바른 변수들의 조합을 제공하지 못한다면 아무리 좋은 성능의 알고리즘도 제 효과를 발휘할 수 없다. 잠깐 언급했듯이 변수 엔지니어링은 크게 두 가지로 나누어 볼 수 있는데, 하나는 데이터 수집 이전에 이론을 바탕으로 변수를 선정하는 것이고 다른 하나는 데이터 수집 이후 분석과정에서 필요한 변수들을 정규화를 통해 선별하는 것이다. 전자는 앞의 이론 수립단계에서 결정되어야 하는 부분이지만, 후자의 경우는 ML 분석과정에서 영향력이 약하다고 판단되는 변수들을 고의로 탈락시키는 등의 사후처방이다. 여기에서는 Lasso 회귀분석(Tibshirani, 2011)과 같은 방법들을 이용하여 가장 큰 영향을 미치는 변수들만을 추려내는 것도 가능하다.

데이터 분석의 마지막 고려사항으로는 하이퍼파라미터 튜닝이 있다. 머신러닝 알고리즘은 각 알고리즘마다 조율해줘야 하는 세부적인 지표들이 있다. 심층신경망을 예로 들자면, 은닉층의 개수, 은닉층 퍼셉트론 수, 활성화 함수, 아웃풋 함수, 데이터 주입방식, 최적화 방법, 연산 반복 수 등 여러 하이퍼파라미터를 갖는다. 이들은 연구자가 직접 설정해줘야 하며, 머신러닝의 성능에 큰 영향을 미치기 때문에, 최적의 하이퍼파라미터를 찾아내는 것은 매우 중요한 일이다. 특히, 하이퍼

파라미터 설정은 모형의 과적합, 즉 주어진 샘플을 너무 과도하게 설명하게 되어 일반화를 잃어버리는 현상과도 연관이 깊기 때문에 그 중요성이 높다. 연구자들은 HRA를 수행하는 과정에서 특정 데이터, 특정 알고리즘, 그리고 특정 하이퍼파라미터 간 최적의 조합을 경험적으로 찾으려는 노력을 경주해야 할 것이다.

4.6 의사결정(Decision making)

마지막은 분석결과를 토대로 의사결정을 하는 단계이다. 물론 최종 의사결정은 권한을 지닌 관리자의 몫이지만 이와 관련하여서도 고민해봐야 할 여지는 충분히 있다. 특히 이 과정에서는 데이터기반의 의사결정이 근본적으로 갖는 문제에 대해 철학적이고 윤리적인 고민이 동반되어야 한다. 이와 관련하여서는 다음과 같은 이슈를 던져 볼 수 있다. 의사결정에 있어 데이터와 직관(intuition) 중 어느 것에 얼마나 의존해야 하는가의 문제이다. 데이터분석은 가장 수학적으로 논리적인 답을 찾아주지만, 결국 그것은 주어진 데이터가 갖는 정보 이상의 시사점을 가져다 줄 수는 없다. 거기다 데이터 자체가 완벽하다는 보장도 없다. 사실 이러한 문제는 직관의 경우도 마찬가지인데 많은 경우에서 직관은 훌륭한 답을 내놓지만, 역시나 실패하는 경우도 많기 때문이다. 또한 데이터가 완벽하지 못한 것과 마찬가지로 인간의 지각 역시 완벽하지 못하다. 그렇다면 가장 좋은 방법은 이 두 가지가 서로 상호작용하는 것이라 할 수 있다(King, 2016). 앞으로의 연구들이 여기에 관심을 가진다면, 데이터분석의 결과물과 의사결정권자의 지각이 어떠한 방식으로 상호작용해야

좋은지 찾아내는 것도 아주 중요한 연구주제가 될 것이다.

V. 결론

본 연구는 최근 해외연구들을 중심으로 그 관심이 커지고 있는 HRA를 국내에 소개하고 지금까지의 연구흐름을 살펴봄으로써 시사점 및 향후연구방향을 제언하기 위해 수행되었다. 이를 위해 HRA와 관련된 해외연구들을 문헌고찰 하였으며, 특히 2016년 이후부터 최근까지 SSCI급 저널에 실린 연구들을 면밀히 검토하였다. 문헌고찰을 통해 알 수 있었던 HRA 연구흐름의 특징은 개념적인 논의가 많았던 데 비해 상대적으로 HRA를 실제로 적용해보는 실증연구의 시도가 적었다는 점이었다. 또한, 근래 이슈가 되고 있는 머신러닝과 같은 여러 최신 분석기술들의 적용이 미비하다는 점도 연구자들이 관심을 가져봐야 할 부분이었다. 연구의 마지막 단계에서는 살펴본 HRA 연구흐름을 바탕으로 향후 HRA가 나아가야 할 하나의 길로서 머신러닝을 활용한 HRA와 그 프로세스를 제안하였다. 그리고 각 프로세스의 단계별로 향후 연구자들이 관심을 가져야 할 이슈들을 논의해보았다.

위 내용들을 바탕으로 본 연구는 다음과 같은 이론적 시사점을 제공한다. 첫째, 해외연구들을 중심으로 최근 HRA에 대한 관심이 커지고 있음을 시사한다. 본 연구의 문헌고찰 과정들을 통해 HRA와 관련된 수많은 연구들이 진행되고 있다는 점과 이와 관련된 다양한 이슈들이 논의되고 있음을 알 수 있었다. 앞서도 언급하였듯이 데이터분석

의 결과를 통해 의사결정에 객관성을 높이고 자하는 노력은 비즈니스 분야 전반에 이미 널리 퍼져있으며, HR 분야 역시 이러한 흐름을 따르고 있다. 이 같은 해외연구흐름은 국내 연구자들도 이제 HRA에 대한 관심을 가질 필요가 있음을 시사한다.

둘째, 현재 HRA의 연구가 가지고 있는 부족함을 해결해줄 수 있는 방법론으로 머신러닝의 필요성을 강하게 시사한다. HRA 연구들의 문헌고찰을 통해 몇 가지 연구흐름의 특징을 파악할 수 있었는데, 그 중에서 연구흐름의 문제점으로 실증연구 부족과 고도화된 방법론의 부재를 확인할 수 있었다. 이 두 문제점은 데이터분석의 단계들 중에서도 예측분석을 제공할 수 있으나 여부와 맞닿아있다고 볼 수 있다. 궁극적으로 HRA는 현장의 의사결정을 도울 수 있는 분석결과를 제시해야 하는데, 이를 위해서는 현상을 설명하는 데 그치는 분석이 아니라 주어진 데이터를 통해 확인되지 않은 값을 예측하는 분석이 필요하다. 딥러닝을 포함한 머신러닝 알고리즘들은 이러한 예측분석에 적합한 분석도구들이기 때문에 현재 HRA에 꼭 맞는 분석방법이라 할 수 있는 것이다.

셋째, 연구주제로서 머신러닝을 활용한 HRA(ML-HRA)의 가능성을 시사한다. 본 연구에서는 기존의 HRA 프로세스를 바탕으로 머신러닝을 활용한 HRA 프로세스를 제안하고 각 단계별로 연구자들이 논의해야 할 사항들을 소개하고 있다. 그 내용을 보면, 이론의 수립, 방법론의 사용, 그리고 분석결과 해석까지 연구자들이 학문적으로 탐구하고 논의해야 할 내용들이 무궁무진하다는 것을 알 수 있다. 이는 HRA가 학문적으로도 충분히 자리 잡을 수 있는 연구 분야임을 의미한다.

본 연구는 이론적 시사점 외에도 중요한 실무적 시사점 역시 가지고 있다. 최신 방법론들을 통해 한 번 더 발전할 기회를 얻은 HRA는 앞으로 실무자들에게도 다양한 HR 요소들을 예측하고 이에 대응할 수 있는 방법들을 내놓기 시작할 것이다. 관련 연구들이 축적되고 또 그 속에서 여러 창의적인 아이디어들이 등장하게 되면, HRA는 더 유용하고 효과적인 시사점들을 실무자들에게 제공할 수 있을 것이다. 지금은 일부 기술적 선두 기업들만이 HRA를 활용하고 있지만, 이제는 국내의 기업과 실무자들도 HRA의 도입을 적극적으로 고려하고 준비해야 할 것이다. 본 연구에서 다루고 있는 HRA 프로세스와 각 단계별 논의들은 연구자들뿐만 아니라 실무자들도 함께 고민해봐야 할 내용이며, 특히 분석결과의 해석 및 분석과정에서의 윤리적 문제 등은 실무자들에게 더 중요한 논의사항이 될지도 모른다.

오래전부터 연구자 및 실무자들은 경영상의 다양한 의사결정에 있어 객관성을 담보하고 타당성을 높이기 위해 고민해왔고 증거기반 의사결정(evidence-based decision making)과 비즈니스 애널리틱스(business analytics)는 그러한 고민의 결과물이다. 다만, 다른 이웃 분야들과 달리 인사관리 분야는 그 대상이 인간이기 때문에 상대적으로 그 수용이 늦어지고 있다. 하지만 그럼에도 불구하고 조심스럽지만 그것을 가능케 하려는 노력들이 HRA 분야에서 일어나고 있다. 기술은 발전하며 기업은 경쟁을 멈추지 않는다. HRA는 우리가 앞으로 반드시 만나야 할 필연일지 모른다. 본 연구는 이러한 상황에서 국내 연구자들에게 HRA를 소개하고 주목해야 할 과제들을 전달하기 위해 수행되었다. 본 연구

의 정리와 제안들이 향후 연구자들에게 도움이 될 수 있기를 바란다.

참고문헌

- Alao, D. A. B. A., & Adeyemo, A. B. (2013). Analyzing employee attrition using decision tree algorithms. *Computing, Information Systems, Development Informatics and Allied Research Journal*, 4(1), 17-28.
- Angrave, D., Charlwood, A., Kirkpatrick, I., Lawrence, M., & Stuart, M. (2016). HR and analytics: why HR is set to fail the big data challenge. *Human Resource Management Journal*, 26(1), 1-11.
- Baesens, B., De Winne, S., & Sels, L. (2017). Is your company ready for HR analytics?. *MIT Sloan Management Review*, 58(2), 20.
- Ben-Gal, H. C. (2019). An ROI-based review of HR analytics: practical implementation tools. *Personnel Review*, 48(6), 1429-1448.
- Bolino, M. C. (1999). Citizenship and impression management: Good soldiers or good actors?. *Academy of Management Review*, 24(1), 82-98.
- Boudreau, J., & Cascio, W. (2017). Human capital analytics: why are we not there?. *Journal of Organizational Effectiveness: People and Performance*, 4(2), 119-126.
- Chamorro-Premuzic, T., Akhtar, R., Winsborough, D., & Sherman, R. A. (2017). The datafication of talent: How technology is advancing the science of human potential at work. *Current Opinion in Behavioral Sciences*, 18, 13-16.

- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
- Claus, L. (2019). HR disruption—Time already to reinvent talent management. *BRQ Business Research Quarterly*, 22(3), 207-215.
- Earley, C. E. (2015). Data analytics in auditing: Opportunities and challenges. *Business Horizons*, 58(5), 493-500.
- Esmaieeli Sikaroudi, A. M., Ghousi, R., & Sikaroudi, A. (2015). A data mining approach to employee turnover prediction (case study: Arak automotive parts manufacturing). *Journal of Industrial and Systems Engineering*, 8(4), 106-121.
- Gelbard, R., Ramon-Gonen, R., Carmeli, A., Bittmann, R. M., & Talyansky, R. (2018). Sentiment analysis in organizational work: Towards an ontology of people analytics. *Expert Systems*, 35(5), e12289.
- Han, H., Wang, W. Y., & Mao, B. H. (2005). Borderline-SMOTE: A new over-sampling method in imbalanced data sets learning. In *International conference on intelligent computing* (pp. 878-887). Springer, Berlin, Heidelberg.
- Hamilton, R. H., & Sodeman, W. A. (2020). The questions we ask: Opportunities and challenges for using big data analytics to strategically manage human capital resources. *Business Horizons*, 63(1), 85-95.
- Jantan, H., Hamdan, A. R., & Othman, Z. A. (2010). Human talent prediction in HRM using C4. 5 classification algorithm. *International Journal on Computer Science and Engineering*, 2(8), 2526-2534.
- Jordan, M. I., & Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245), 255-260.
- Khera, S. N., & Divya. (2018). Predictive Modelling of Employee Turnover in Indian IT Industry Using Machine Learning Techniques. *Vision*, 23(1), 12-21.
- Kryscynski, D., Reeves, C., Stice-Lusvardi, R., Ulrich, M., & Russell, G. (2018). Analytical abilities and the performance of HR professionals. *Human Resource Management*, 57(3), 715-738.
- Lepeniotti, K., Bousdekis, A., Apostolou, D., & Mentzas, G. (2020). Prescriptive analytics: Literature review and research challenges. *International Journal of Information Management*, 50, 57-70.
- Levenson, A. (2018). Using workforce analytics to improve strategy execution. *Human Resource Management*, 57(3), 685-700.
- Levenson, A. (2011). Using targeted analytics to improve talent decisions. *People and Strategy*, 34(2), 34.
- Lismont, J., Vanthienen, J., Baesens, B., & Lemahieu, W. (2017). Defining analytics maturity indicators: A survey approach. *International Journal of Information Management*, 37(3), 114-124.
- King, K. G. (2016). Data analytics in human resources: A case study and critical review. *Human Resource Development Review*, 15(4), 487-495.
- Marler, J. H., & Boudreau, J. W. (2017). An evidence-based review of HR Analytics. *The International Journal of Human*

- Resource Management*, 28(1), 3-26.
- Mayfield, M., Mayfield, J., & Lunce, S. (2003). Human resource information systems: A review and model development. *Journal of Competitiveness Studies*, 11(1), 139.
- McIver, D., Lengnick-Hall, M. L., & Lengnick-Hall, C. A. (2018). A strategic approach to workforce analytics: Integrating science and agility. *Business Horizons*, 61(3), 397-407.
- Minbaeva, D. B. (2018). Building credible human capital analytics for organizational competitive advantage. *Human Resource Management*, 57(3), 701-713.
- Nankervis, A., Connell, J., Cameron, R., Montague, A., & Prikshat, V. (2019). 'Are we there yet?' Australian HR professionals and the Fourth Industrial Revolution. *Asia Pacific Journal of Human Resources*. doi:10.1111/1744-7941.12245
- Ngai, E.W.T. and Wat, F.K.T. (2006), "Human resource information systems: a review and empirical analysis", *Personnel Review*, 35(3), 297-314.
- Organ, D., Podsakoff, P., & MacKenzie, S. (2006). *Organizational Citizenship Behavior: Its Nature, Antecedents, and Consequences*. Thousand Oaks, California.
- Pape, T. (2016). Prioritising data items for business analytics: Framework and application to human resources. *European Journal of Operational Research*, 252(2), 687-698.
- Pennachin, C., & Goertzel, B. (2007). Contemporary approaches to artificial general intelligence. In *Artificial General Intelligence* (pp. 1-30). Springer, Berlin, Heidelberg.
- Ransbotham, S., Kiron, D., & Prentice, P. K. (2015). The talent dividend. *MIT Sloan Management Review*, 56(4), 1.
- Rasmussen, T., & Ulrich, D. (2015). Learning from practice: how HR analytics avoids being a management fad. *Organizational Dynamics*, 44(3), 236-242.
- Rebele, R. (2019). Can We Really Test People for Potential?. *MIT Sloan Management Review*, 60(3), 10-13.
- Reiter, J. P. (2005). Using CART to generate partially synthetic public use microdata. *Journal of Official Statistics*, 21(3), 441.
- Safarishahrbiari, A. (2018). Workforce forecasting models: A systematic review. *Journal of Forecasting*, 37(7), 739-753.
- Saradhi, V. V., & Palshikar, G. K. (2011). Employee churn prediction. *Expert Systems with Applications*, 38(3), 1999-2006.
- Schiemann, W. A., Seibert, J. H., & Blankenship, M. H. (2018). Putting human capital analytics to work: Predicting and driving business success. *Human Resource Management*, 57(3), 795-807.
- Sexton, R. S., McMurtry, S., Michalopoulos, J. O., & Smith, A. M. (2005). Employee turnover: a neural network solution. *Computers & Operations Research*, 32(10), 2635-2651.
- Shah, N., Irani, Z., & Sharif, A. M. (2017). Big data in an HR context: Exploring organizational change readiness, employee attitudes and behaviors. *Journal of Business Research*, 70, 366-378.
- Simón, C., & Ferreiro, E. (2018). Workforce

- analytics: A case study of scholar-practitioner collaboration. *Human Resource Management*, 57(3), 781-793.
- Tang, Y., Zhang, Y. Q., Chawla, N. V., & Krasser, S. (2008). SVMs modeling for highly imbalanced classification. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 39(1), 281-288.
- Tannenbaum, S. I. (1990). Human resource information systems: User group implications. *Journal of Systems management*, 41(1), 27.
- Tambe, P., Cappelli, P., & Yakubovich, V. (2019). Artificial intelligence in human resources management: Challenges and a path forward. *California Management Review*, 61(4), 15-42.
- Tibshirani, R. (2011). Regression shrinkage and selection via the lasso: a retrospective. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 73(3), 273-282.
- Tkáč, M., & Verner, R. (2016). Artificial neural networks in business: Two decades of research. *Applied Soft Computing*, 38, 788-804.
- Tursunbayeva, A., Di Lauro, S., & Pagliari, C. (2018). People analytics—A scoping review of conceptual boundaries and value propositions. *International Journal of Information Management*, 43, 224-247.
- Valle, M. A., & Ruz, G. A. (2015). Turnover prediction in a call center: behavioral evidence of loss aversion using random forest and Naïve Bayes algorithms. *Applied Artificial Intelligence*, 29(9), 923-942.
- van der Laken, P., Bakk, Z., Giagkoulas, V., van Leeuwen, L., & Bongenaar, E. (2018). Expanding the methodological toolbox of HRM researchers: The added value of latent bathtub models and optimal matching analysis. *Human Resource Management*, 57(3), 751-760.
- Vargas, R., Yurova, Y. V., Ruppel, C. P., Tworoger, L. C., & Greenwood, R. (2018). Individual adoption of HR analytics: a fine grained view of the early stages leading to adoption. *The International Journal of Human Resource Management*, 29(22), 3046-3067.
- Wang, L., & Cotton, R. (2018). Beyond Moneyball to social capital inside and out: The value of differentiated workforce experience ties to performance. *Human Resource Management*, 57(3), 761-780.
- Wang, S., Li, Z., Chao, W., & Cao, Q. (2012). Applying adaptive over-sampling technique based on data density and cost-sensitive SVM to imbalanced learning. In *The 2012 International Joint Conference on Neural Networks (IJCNN)* (pp. 1-8). IEEE.
- Ward, M. J., Marsolo, K. A., & Froehle, C. M. (2014). Applications of business analytics in healthcare. *Business Horizons*, 57(5), 571-582.
- Xu, L. (2020). Synthesizing Tabular Data using Conditional GAN (Doctoral dissertation, Massachusetts Institute of Technology).
- Yarkoni, T., & Westfall, J. (2017). Choosing prediction over explanation in psychology: Lessons from machine learning.

Perspectives on Psychological Science,

12(6), 1100-1122.

■ 저자 소개

송기륜(Song, Gi Ryung)

- 경북대학교 경상대학 경영학부 박사수료생이며, 연구 분야는 조직행동, OCB, CWB, HRM, HRA 등이다.

김경석(Kim, Kyoung Seok)

- 경북대학교 경상대학 경영학부 교수이며, 연구 분야는 조직행동, 비과업행동, OCB, CWB, 감정노동, HRM 등이다.

〈Abstract〉

Review and Suggestions of HR Analytics

Song, Gi Ryung* · Kim, Kyoung Seok**

HR analytics is an effort and a new methodology for more objectively and effective evidence-based decision-making with the desire of data science that has blown into the HRM field. The interest in HR analytics, which started in the early 2000s, has emerged with the advancement of technologies such as artificial intelligence and big data analytics, and many discussions are already underway abroad. On the other hand, there are not enough research related to HR analytics in Korea, so further discussions are required. Therefore, this study summarizes and proposes the research trends and implications of HR analytics through the following three steps, and proposes a framework of HR analytics that future researchers can base on.

First, in the first step, we review the literature of HR analytics studies and derive their implications. As a result of the study, three implications were obtained, each of which is that a sufficient number of conceptual research related to HR analytics has been made, that empirical research is insufficient, and that a more advanced methodology is urgently needed.

In the second step, based on the review of the literature, we will examine the current position of HR analytics and what advanced methodologies are needed for HR analytics in the future. As a result of the research, it can be seen that HR analytics remains at the stage of transitioning from technical analysis to predictive analysis in the business analytics value model, and advanced methodologies such as machine learning are needed to move to prediction and prescription analysis in the future.

Finally, we propose a framework for future researchers based on all the previous contents. This framework, as the final result of this study, includes the process of HR analytics using machine learning, the key questions for each process, and the corresponding research issues.

Key words: HR analytics, artificial intelligence in HR, machine learning in HR,
HR predictive analytics, HR prescriptive analytics

* Ph. D. Candidate, School of Business Administration, Kyungpook National University

** Professor, School of Business Administration, Kyungpook National University